

**Sequence Design e Deep Reinforcement
Learning: Uma nova perspectiva no
tratamento da Hemofilia B**

Arthur Moriggi Pimenta

DISSERTAÇÃO APRESENTADA AO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
DA UNIVERSIDADE DE SÃO PAULO
PARA OBTENÇÃO DO TÍTULO DE
MESTRE EM CIÊNCIAS

Programa: Ciência da Computação
Orientador: Prof. Dr. Roberto Hirata Junior

São Paulo
Maio de 2025

**Sequence Design e Deep Reinforcement
Learning: Uma nova perspectiva no
tratamento da Hemofilia B**

Arthur Moriggi Pimenta

Esta é a versão original da dissertação
elaborada pelo candidato Arthur
Moriggi Pimenta, tal como
submetida à Comissão Julgadora.

*O conteúdo deste trabalho é publicado sob a licença CC BY 4.0
(Creative Commons Attribution 4.0 International License)*

Agradecimentos

Primeiramente, agradeço a Deus, que me capacita, me fortalece e me inspira a ser uma pessoa melhor a cada dia. À minha família e aos amigos, cujo apoio tornou esta jornada mais leve. Um agradecimento especial à minha companheira, **Kamylle Barreto**, por me oferecer toda a estrutura e o suporte emocional necessários ao longo deste percurso. Ao meu orientador, **Prof. Dr. Roberto Hirata Junior**, pela orientação dedicada, pela confiança depositada em mim e pelo apoio constante durante o desenvolvimento desta pesquisa. Por fim, ao **Dr. Tiago José da Silva Lopes**, pela parceria essencial e pelo apoio técnico e científico que foram fundamentais para a concretização deste projeto.

Resumo

Arthur Moriggi Pimenta. **Sequence Design e Deep Reinforcement Learning: Uma nova perspectiva no tratamento da Hemofilia B.** Dissertação (Mestrado). Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2025.

Neste trabalho, propomos o desenvolvimento de um pipeline computacional para o *design* de proteínas substitutas ao Fator IX de coagulação humana (FIX), com o objetivo de otimizar seu uso terapêutico no tratamento da hemofilia B. A metodologia combina aprendizado por reforço profundo com técnicas avançadas de modelagem estrutural e análise de interação molecular. O pipeline é dividido em três módulos principais: (i) Condições Iniciais, responsável por gerar a sequência inicial de aminoácidos e avaliar sua estrutura; (ii) Trereco para realizar mutações na sequência inicial que minimizam, no qual um agente *GenSeq* é treinado com aprendizado por aximizem a similaridade estrutural com o FIX; e (iii) Geração de Sequências, que utiliza o agente treinado para explorar o espaço de sequências. A avaliação das proteínas geradas inclui a análise de similaridade estrutural, o estudo das interações moleculares com outras macromoléculas, como o Fator VIII de coagulação humana (FVIII), e a avaliação do perfil imunológico. Os resultados demonstram que as proteínas propostas apresentam alta similaridade estrutural com o FIX nativo, interações moleculares eficientes com o FVIII e perfis imunogênicos comparáveis ou mais favoráveis que o FIX. O pipeline mostrou-se promissor como ferramenta para o *design* de proteínas terapêuticas personalizadas e de baixo risco imunológico para aplicação clínica no tratamento da hemofilia B.

Palavras-chave: Hemofilia B, Fator IX, Design de proteínas, Aprendizado por Reforço, PPO, Imunogenicidade, Docking Molecular.

Abstract

Arthur Moriggi Pimenta. **Sequence Design and Deep Reinforcement Learning: A New Frontier in Hemophilia B Management.** Thesis (Master's). Institute of Mathematics and Statistics, University of São Paulo, São Paulo, 2025.

This work proposes the development of a computational pipeline for designing substitute proteins for Human coagulation Factor IX (FIX), aiming to optimize their therapeutic application in the treatment of hemophilia B. The methodology combines deep reinforcement learning with advanced structural modeling and molecular interaction analysis techniques. The pipeline is divided into three main modules: (i) Initial Conditions, responsible for generating the initial amino acid sequence and predicting its structure; (ii) Training, where an agent named *GenSeq* is trained by deep reinforcement learning to perform mutations that maximize structural similarity to FIX; and (iii) Sequence Generation, where the trained agent explores the space of sequences. The evaluation of the generated proteins includes structural similarity analysis, molecular docking studies with Human coagulation Factor FVIII (FVIII), and the immunogenic profile evaluation. The results demonstrate that the designed proteins present high structural similarity to the native FIX, efficient molecular interactions with FVIII, and immunogenicity profiles comparable to or lower than the reference FIX. The proposed pipeline proved to be a promising tool for the design of personalized therapeutic proteins with reduced immunogenic risk for clinical application in the treatment of hemophilia B.

Keywords: Hemophilia B, Factor IX, Protein Design, Reinforcement Learning, PPO, Immunogenicity, Molecular Docking.

Listas de abreviaturas

RL	Aprendizado por Reforço (<i>Reinforcement Learning</i>)
DRL	Aprendizado Profundo por Reforço (<i>Deep Reinforcement Learning</i>)
MSA	Alinhamento múltiplo de sequências (<i>Multiple Sequence Alignment</i>)
IS	Idêntidade de Sequência
TMScore	Escores de Modelagem de Template (<i>Template Modeling Score</i>)
LLM	Modelo Grande de Linguagem (<i>Large Language Model</i>)
PPO	(<i>Proximal Policy Optimization</i>)
IMI	Imuno Índice
Af	<i>Binding affinity</i>
Fr	Frequência de ocorrência de um alelo na humanidade
F_{seq}	Função que mapeia uma estrutura proteica em uma sequência de aminoácidos
F_{obj}	Função objetivo
H	Heurística
A	Agente
MMC	Método de Monte Carlo
MPNN	Rede Neural de Passagem de Mensagem (<i>Message Passing Neural Network</i>)
RMSD	Raiz do Erro Quadrático Médio (<i>Root Mean Square Deviation</i>)
FIX	Fator IX
FVIII	Fator VIII
FIXa	Fator IX ativado
FVIIIa	Fator VIII ativado
E_{FIX}	Estrutura do Fator IX
E_{ini}	Estrutura inicial vinculada à sequência gerada pelo <i>ProteinMPNN</i>
S_{ini}	Sequência inicial vinculada à estrutura E_{ini}
Er_0	Erro inicial
P_{val}	Conjunto de posições válidas
R_{val}	Conjunto de resíduos válidos
N_{rep}	Número máximo de vezes que um resíduo pode ser utilizado

M_{max}	Número máximo de mutações
CS	<i>Conservation Score</i>
$AminoDist$	Função de distância ou similaridade entre dois aminoácidos
$Encoder$	Dicionário que mapeia um aminoácido em um vetor de características
MDS	<i>Multi Dimensional Scaling</i>
S_{enc}	Sequência codificada
Env_I	Ambiente de aprendizado no primeiro estágio de treinamento
Env_{II}	Ambiente de aprendizado no segundo estágio de treinamento
R_I	Recompensa no primeiro estágio de treinamento
R_{II}	Recompensa no segundo estágio de treinamento
CMS	<i>Contact Molecular Surface</i>
$IBSASA$	<i>Interface Buried Solvent Accessible Surface Area</i>
$SASA$	<i>Solvent Accessible Surface Area</i>
DDG	<i>Delta Gibbs Free Energy of Binding</i>
SAP	<i>Spatial Aggregation Propensity Score</i>
PDB	<i>Protein Data Bank</i>
IME	Instituto de Matemática e Estatística
USP	Universidade de São Paulo

Listas de figuras

1.1	<i>Sequence Design</i>	2
1.2	<i>Sequence Design</i> baseado em busca	2
1.3	<i>Sequence Design</i> baseado em <i>Deep Learning</i>	3
3.1	Componentes de uma proteína	10
3.2	Aminiácidos	10
3.3	Exemplo de conformação protéica	11
3.4	Atuação do FIXa na ativação do FX	11
3.5	Interação entre FIXa e FVIIIa	12
3.6	Estrutura alvo - Domínio protease do Fator IXa	12
3.7	FIXa Conservation Score	16
3.8	Distâncias entre aminoácidos	17
3.9	Arquitetura de rede neural	19
3.10	Neurônio processando sinal	19
4.1	<i>Pipeline</i> proposto de <i>Sequence Design</i> .	25
4.2	Proteína gerada 63 (verde) alinhada com o FVIII (azul)	26
5.1	Obtenção das condições iniciais	29
5.2	Construção e uso do <i>Encoder</i> .	31
5.3	Escolha da dimensionalidade dos Embeddings	31
5.4	Exemplo de mutação. O aminoácido A na posição 3 está sendo substituído pelo o aminoácido C	32
5.5	Arquitetura da rede neural do Agente (<i>GenSeq</i>)	33
5.6	Primeiro estágio de treinamento	37
5.7	Comparação do Agente pré treinado com um Agente aleatório	38
5.8	Média móvel das recompensas por episódio - treino	38
5.9	Segundo estágio - Treino	43
5.10	Comparação do Agente treinado com um Agente aleatório	44

5.11	Média móvel das recompensas por episódio - treino	44
5.12	Gerando sequência otimizada	46
6.1	Variação da similaridade entre as sequências geradas e o FIX	47
6.2	Alinhamento entre FIX (em azul) e a proteína ID 34 (em vermelho)	48
6.4	Comparação do IMI entre as proteínas geradas e o FIX	49
6.5	IMI calculado para cada grupo de alelo	50
6.6	Resultado do CMS entre as proteínas geradas e o fator VIII	51
6.7	Resultado do IBSASA entre as proteínas geradas e o fator VIII	51
6.8	Resultado do SAP Score entre as proteínas geradas e o fator VIII	52
6.9	Resultado do DDG entre as proteínas geradas e o fator VIII	52

List of tables

5.1	Hiperparâmetros do PPO	33
5.2	Parâmetros preliminares	37
5.3	Parâmetros preliminares	43
6.1	Generated proteins	48
6.2	Grupos de alelos considerados e a frequência com que ocorrem em seres humanos.	48

Sumário

1	Introdução	1
1.1	Sequence Design	1
1.1.1	Sequence Design baseado em busca	2
1.1.2	<i>Sequence Design</i> baseado em <i>Deep Learning</i>	3
1.2	Objetivos	3
1.3	Contribuições	4
2	Revisão Bibliográfica	5
2.1	Trabalhos relacionados	5
3	Fundamentação teórica	9
3.1	Proteína	9
3.1.1	Estrutura proteíca	10
3.1.2	O Fator IX	11
3.1.3	Docking	13
3.1.4	Resposta Imunológica	14
3.1.5	Mutação	14
3.1.6	Similariedade entre estruturas	14
3.1.7	Conservation Score	16
3.1.8	Similariedade entre aminoácidos	16
3.2	Aprendizado por reforço profundo	17
3.2.1	Processo de Decisão de Markov	17
3.2.2	Redes Neurais	18
3.2.3	Método Actor-Critic	20
3.2.4	PPO	20
3.2.5	Escalonamento Multidimensional (MDS)	21
4	Metodologia	23
4.1	Estrutura do pipeline	23

4.2	Métodos de avaliação	25
5	Desenvolvimento do pipeline	29
5.1	Condições iniciais	29
5.2	Treinamento	30
5.2.1	Ambiente de aprendizado	30
5.2.2	Agente	32
5.2.3	Treinamento - Estágio I	34
5.2.4	Treinamento - Estágio II	38
5.3	Geração de sequências	45
6	Resultados	47
6.1	Resposta imunológica	48
6.2	Docking	50
7	Conclusão	53

Apêndices

A	Comandos e Parametrizações	55
----------	-----------------------------------	-----------

Anexos

Referências	59
--------------------	-----------

Capítulo 1

Introdução

A hemofilia tipo B é uma doença hereditária rara, caracterizada por uma deficiência no Fator IX de coagulação humana (FIX). Os pacientes com a doença enfrentam um risco maior de sofrer com hemorragias graves, tanto internas quanto externas, podendo levar a complicações debilitantes e até mesmo à morte (MANNUCCI, 2020).

Apesar dos avanços notáveis no tratamento da hemofilia nas últimas décadas, muitos desafios ainda persistem. O tratamento tradicional da hemofilia tipo B envolve a infusão de fatores de coagulação recombinantes ou derivados do plasma sanguíneo (S. C. G. e. AL., 2013). Embora eficazes na prevenção de hemorragias, esses tratamentos apresentam limitações significativas, como a necessidade de infusões frequentes devido à curta meia-vida do FIX na circulação, a possibilidade de desenvolvimento de inibidores anti-coagulantes e os elevados custos associados (PIER MANNUCIO MANNUCCI, 2005). Nesse contexto, o desenvolvimento de novas proteínas recombinantes (*Sequence Design*) surge como uma abordagem com potencial de reduzir os custos associados ao tratamento da doença, projetando proteínas sob medida que desempenham a mesma função do FIX, mas com maior estabilidade, reduzindo a frequência de infusões e o risco do desenvolvimento de inibidores.

1.1 Sequence Design

Sequence Design refere-se ao processo de criação ou otimização de uma sequência de aminoácidos que se conformam em uma estrutura tridimensional de interesse. Em outras palavras, consiste em desenvolver uma função F_{seq} que recebe como entrada uma estrutura proteica alvo e retorna a sequência correspondente. Essa tarefa é desafiadora, pois o número de permutações possíveis para uma sequência de aminoácidos cresce exponencialmente com seu tamanho, tornando inviável a busca dentre todas as possibilidades (HAIPENG GONG, 2022).

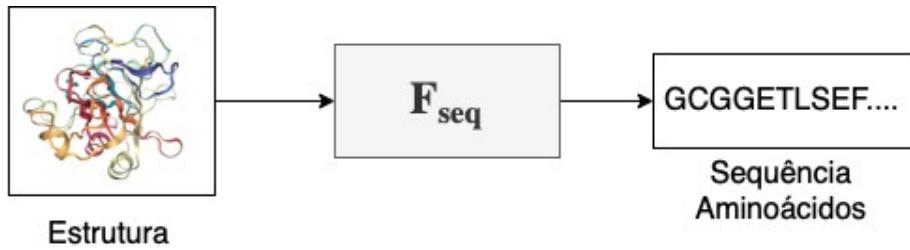


Figura 1.1: Sequence Design se resume a desenvolver uma função F_{seq} que mapeia uma estrutura proteica tridimensional alvo em uma sequência de aminoácidos.

1.1.1 Sequence Design baseado em busca

No Sequence Design baseado em busca, a função F_{seq} é definida por um processo iterativo. Inicialmente, uma sequência de aminoácidos é gerada com base em uma heurística inicial H . Essa sequência é então avaliada por uma função objetivo F_{obj} , responsável por calcular a métrica a ser otimizada. A cada iteração, a nova sequência gerada é comparada com a sequência anterior de acordo com a métrica definida. Se a sequência atual apresentar melhor desempenho, o Agente A a define como nova sequência final. Caso contrário, a sequência final é mantida. Em ambos os cenários, o próximo passo é a aplicação de uma mutação pelo Agente A sobre a sequência atual com o objetivo de explorar novas possibilidades no espaço de busca. Esse processo é repetido até que um critério de parada seja atingido, como um número máximo de iterações ou a convergência da métrica calculada por F_{obj} .

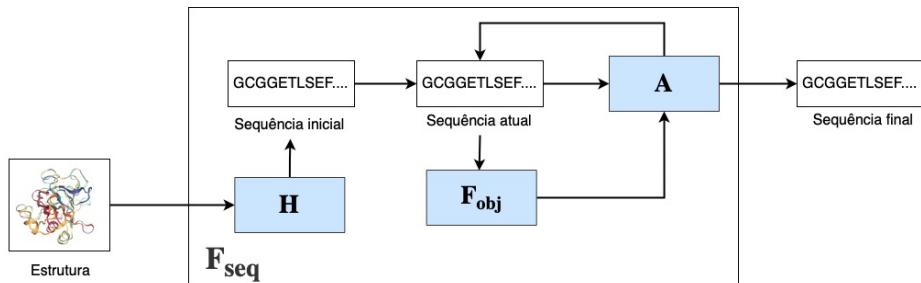


Figura 1.2: Sequence Design baseado em busca define F_{seq} como um processo iterativo que combina uma heurística inicial H , a avaliação por F_{obj} e as modificações realizadas pelo Agente A . O processo é repetido até atingir um número máximo de iterações ou um limiar calculado por F_{obj} .

O software Rosetta (B, 2019) é uma das ferramentas mais amplamente utilizadas para otimização e *design* de proteínas. Ele implementa um *pipeline* iterativo que combina heurísticas de geração de sequências iniciais, avaliações de estabilidade estrutural e técnicas de mutação orientada para explorar o espaço de sequências. Em seu *pipeline*:

- **Heurística inicial (H):** Utiliza a sequência de uma proteína estruturalmente semelhante como ponto de partida.
- **Função objetivo (F_{obj}):** Avalia a energia livre da proteína resultante, considerando fatores como interações de Van der Waals, interações eletrostáticas e ligações de hidrogênio.

- **Agente (A):** Utiliza o Método de Monte Carlo (MMC) para introduzir mutações na sequência e aceitar novas configurações com menor energia livre, guiando iterativamente o processo de otimização.

Abordagens alternativas podem usar a similaridade estrutural como função objetivo, sendo uma métrica amplamente utilizada o *Template Modeling Score* (TMScore) (JEFFREY SKOLNICK, 2004).

1.1.2 *Sequence Design* baseado em *Deep Learning*

Sequence Design baseado em *Deep Learning* define a função F_{seq} a partir de redes neurais artificiais. O trabalho de J. D. e. AL, 2022 por exemplo, determina a F_{seq} como uma rede neural profunda, denominada *ProteinMPNN*, que mapeia de forma direta a estrutura alvo à sequência de aminoácidos. A rede é construída através de uma *Message Passing Neural Network* (MPNN) composta por uma arquitetura *encoder-decoder* que se baseia nas características da estrutura como distância e orientação dos átomos no espaço para fazer previsões (J. D. e. AL, 2022).

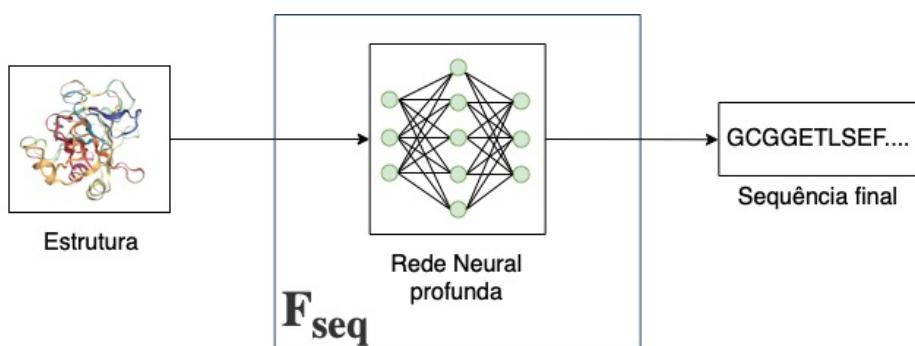


Figura 1.3: *Sequence Design* baseado em *Deep Learning*

1.2 Objetivos

Além de suscitar uma possível resposta imunológica, o tratamento da hemofilia tipo B baseado na infusão de FIX é custoso devido ao pouco tempo de vida da proteína na corrente sanguínea, demandando infusões frequentes. Neste sentido, este trabalho busca responder à seguinte pergunta científica: É possível, através de *Sequence Design*, projetar uma proteína que desempenhe a mesma função do FIX, mas com maior estabilidade, menor imunogenicidade e com necessidade de infusões reduzida?

Para responder a esta questão, formulamos a hipótese de que variantes mais eficazes que o FIX devem preservar sua conformação estrutural. Assim, o objetivo será identificar proteínas estruturalmente semelhantes que atendam aos critérios estabelecidos. Para simplificar o problema, focaremos no projeto do domínio protease, reconhecido como o mais relevante para a função do FIX (DIEST E DOUGALD M. MONROE, 2024).

Nossa dissertação consiste no desenvolvimento de um *pipeline* modular que combina estratégias de *Sequence Design* baseado em busca e baseado em *Deep Learning* para otimiza-

ção de sequências proteicas. Será utilizada a mesma arquitetura da função F_{seq} empregada na abordagem baseada em busca (ver figura 1.2). No entanto, em vez de utilizar um agente que realiza mutações aleatórias, como no *Rosetta*, propõe-se o treinamento de uma rede neural profunda, chamada *GenSeq*, para atuar como o Agente A, sendo capaz de realizar mutações que otimizem a similaridade com a estrutura alvo, isto é, o FIX.

O *GenSeq* será treinado utilizando o algoritmo de aprendizado por reforço profundo *Proximal Policy Optimization* (PPO) (OLEG KLIMOV, 2017). Após o treinamento, será utilizado para gerar variantes de proteínas estruturalmente semelhantes ao FIX por meio de um processo de mutação orientado. As sequências geradas serão avaliadas quanto ao seu potencial para substituir o FIX no tratamento da hemofilia tipo B.

Dessa forma, para responder à pergunta científica proposta, definem-se os seguintes objetivos:

1. Desenvolver um *pipeline* genérico que produza sequências que mimetizem uma estrutura qualquer.
2. Obter um conjunto de sequências de aminoácidos que se conformam em estruturas similares ao FIX baseado na métrica *TMScore*.
3. Avaliar, dentro do conjunto de proteínas obtidas em 1, quais possuem potencial de substituir o FIX de modo tornar o tratamento de Hemofilia tipo B mais acessível e eficiente.

1.3 Contribuições

As contribuições deste trabalho são:

1. O desenvolvimento de proteínas potenciais candidatas a substituir o FIX no tratamento da hemofilia tipo B.
2. Um *pipeline* para *Sequence Design* baseado em Aprendizado por Reforço Profundo, que pode ser adaptado para outras proteínas com estruturas conhecidas.
3. Introdução da métrica IMI (Imuno Índice), que quantifica a propensão de uma proteína gerar uma resposta imunológica adversa.
4. O artefato do modelo de aprendizado por reforço profundo, o *GenSeq*, que pode ser utilizado para geração de novas sequências proteicas a partir da estrutura do FIX (PIMENTA, 2025).
5. O código fonte das implementações e os scripts utilizados para o treinamento do *GenSeq*, bem como a avaliação de similaridade estrutural, *docking* e imunogenicidade das sequências geradas (PIMENTA, 2025).
6. Os arquivos PDB utilizados como entrada para o treinamento do *GenSeq* e para a avaliação das proteínas geradas (PIMENTA, 2025).
7. Apresentação dos resultados no *World Federation of Hemophilia (WFH) 2024*, realizado em Madrid, Espanha, por meio do pôster científico intitulado “*Protein Design and Deep Learning: A New Frontier in Hemophilia B Management*” (TIAGO J. LOPES, 2024)

Capítulo 2

Revisão Bibliográfica

O objetivo deste capítulo é situar o presente trabalho no contexto das contribuições existentes na área de pesquisa. Para isso, analisamos diversas publicações da literatura que estão alinhadas com os objetivos deste estudo.

2.1 Trabalhos relacionados

O tratamento atual para hemofilia B baseia-se na reposição do FIX por meio de proteínas recombinantes ou derivadas do plasma humano. A introdução de fatores de coagulação recombinantes na prática clínica representou um marco no manejo da doença, proporcionando maior segurança e eficácia em comparação com derivados do plasma, reduzindo significativamente os riscos de transmissão de patógenos (CRAIG M. KESSLER, 1995). No entanto, as terapias baseadas na reposição de FIX ainda apresentam desafios substanciais. Devido à curta meia-vida do FIX na circulação, pacientes geralmente necessitam de infusões frequentes para manter níveis terapêuticos adequados, o que aumenta os custos e a complexidade do tratamento (PIER MANNUCCIO MANNUCCI, 2005). Além disso, os pacientes podem desenvolver inibidores, que são anticorpos neutralizantes dirigidos contra o FIX, comprometendo a eficácia do tratamento (SANTAGOSTINO, 2017). Avanços recentes, como o desenvolvimento de variantes do FIX de longa duração como o rFIX-Fc, estenderam a meia-vida da proteína, reduzindo a frequência de infusões (MASSIMO FRANCHINI, 2014). Apesar disso, essas terapias continuam a ser custosas e, em alguns casos, limitadas pela resposta imunológica do paciente.

O design de proteínas surge como uma alternativa com potencial de desenvolver tratamentos mais eficientes. Trata-se de um campo emergente que busca criar ou modificar proteínas para otimizar suas funções biológicas, estabilidade estrutural ou características terapêuticas. Os avanços nessa área têm sido impulsionados pelo aprimoramento de tecnologias de modelagem molecular e pelo uso de ferramentas computacionais especializadas. O software Rosetta (B, 2019) por exemplo, foi uma das primeiras ferramentas amplamente utilizadas para predição de estruturas proteicas. Seu funcionamento baseia-se na minimização da energia livre de uma proteína, modelando interações moleculares fundamentais como interações de Van der Waals, forças eletrostáticas, ligações de hidrogênio e efeitos hidrofóbicos. A predição estrutural utilizando o Rosetta fundamenta-se no princípio de

que a conformação nativa de uma proteína corresponde a conformação de menor energia livre. O processo é iterativo e inicia-se com a geração de modelos estruturais iniciais, frequentemente por meio da montagem de fragmentos, em que pequenos segmentos estruturais de proteínas conhecidas são recombinados para gerar conformações aproximadas da proteína alvo. Para cada modelo gerado é estimado a energia livre da conformação. A partir dessas estimativas, o Rosetta aplica métodos estocásticos, como Monte Carlo Simulated Annealing, para explorar diferentes conformações e minimizar a função de energia, conduzindo a um refinamento progressivo da estrutura modelada. Os modelos que apresentam menores valores são considerados candidatos mais prováveis para representar a estrutura nativa da proteína em estudo.

JUMPER, 2021 introduziu o *AlphaFold*, um modelo que representou um avanço significativo na predição estrutural de proteínas, ao introduzir uma abordagem baseada em *deep learning* que superou métodos computacionais tradicionais. O problema da predição estrutural pode ser formalmente descrito como a minimização da função de energia livre associada à conformação da proteína. Diferentemente dos métodos tradicionais que exploraram o espaço conformacional por meio de amostragem estocástica, o *AlphaFold* aprende diretamente um mapa de distâncias e ângulos que minimiza essa função de energia. O modelo utiliza redes neurais treinadas em bancos de dados contendo estruturas proteicas determinadas experimentalmente, como as obtidas por cristalografia de raios X, espectroscopia por ressonância magnética nuclear (RMN) e criomicroscopia eletrônica. A base teórica do *AlphaFold* fundamenta-se na modelagem das interações residuais a partir de alinhamentos múltiplos de sequências (MSA, Multiple Sequence Alignments) e do aprendizado das representações espaciais dos resíduos por meio de camadas de atenção baseadas em grafos. O modelo recebe como entrada uma sequência de aminoácidos e gera um conjunto de representações internas (*embeddings*) que capturam informações sobre a proximidade e orientação relativa dos resíduos na estrutura tridimensional da proteína. O modelo foi amplamente validado por meio de sua participação na edição 14 do CASP (*Critical Assessment of Structure Prediction*), uma avaliação que compara métodos de predição de estrutura proteica com dados experimentais inéditos. No CASP14, o *AlphaFold* demonstrou um desempenho quase equivalente ao de técnicas experimentais. Esse avanço revolucionou o campo da biologia estrutural, reduzindo a dependência exclusiva de métodos experimentais e abrindo novas possibilidades para a engenharia de proteínas e a compreensão de doenças associadas a dobramentos proteicos anômalos.

Z. L. e. AL, 2022 apresentaram o *ESMFold*, um modelo baseado em *transformers* capaz de realizar a predição de estruturas proteicas diretamente a partir de sequências de aminoácidos. Diferentemente de modelos como o *AlphaFold*, que fazem uso extensivo de alinhamentos múltiplos de sequências (MSA, Multiple Sequence Alignments) e atenção baseada em grafos para inferir interações residuais, o *ESMFold* prioriza a velocidade de processamento, permitindo uma predição rápida de estruturas com precisão moderada. A arquitetura do *ESMFold* baseia-se no modelo de linguagem proteica ESM-2, um *transformer* pré-treinado em grandes bancos de dados de sequências biológicas. Esse modelo aprende representações internas que capturam informações evolutivas e estruturais implícitas, sem depender explicitamente de MSAs. A predição estrutural ocorre por meio da inferência direta da topologia tridimensional da proteína a partir dessas representações, minimizando a necessidade de computação intensiva e permitindo um tempo de inferência reduzido.

2.1 | TRABALHOS RELACIONADOS

Embora o *ESMFold* não alcance a precisão estrutural do *AlphaFold*, sua abordagem é extremamente vantajosa para aplicações que exigem triagem de alto desempenho, como análises em larga escala e estudos preliminares de modelagem proteica. Sua rapidez permite que estruturas sejam geradas em segundos, enquanto o *AlphaFold* pode demandar minutos a horas, dependendo da complexidade da proteína analisada.

Ferramentas como o *ProteinMPNN* J. D. e. AL, 2022 utilizam arquiteturas baseadas em *Message Passing Neural Networks* (MPNNs) para prever sequências de aminoácidos capazes de adotar conformações tridimensionais específicas. Diferentemente dos métodos tradicionais de *design* de proteínas, que frequentemente utilizam abordagens estocásticas ou heurísticas para otimizar sequências, como o *Rosetta*, o *ProteinMPNN* emprega *deep learning* para explorar de maneira eficiente o espaço de sequências e gerar variantes estruturalmente viáveis. O modelo opera sobre a representação estrutural de uma proteína como um grafo, onde os resíduos de aminoácidos correspondem a nós e as interações entre eles são representadas por arestas ponderadas. A passagem de mensagens ocorre entre os nós vizinhos, permitindo que o modelo aprenda padrões de interações residuais que favorecem a estabilidade estrutural da proteína. O modelo consiste de 3 camadas de *encoder* e 3 de *decoder* seguidos de uma camada escondida de 128 neurônios prevendo a sequência de aminoácidos de modo auto regressivo, do terminal N ao C.

ANGERMUELLER C, 2019 apresentaram o *DyNA PPO*, que consiste em uma abordagem de *desing* de sequências proteicas baseada em aprendizado por reforço profundo (*Deep Reinforcement Learning*, DRL), atualizando seus parâmetros através do algoritmo *Proximal Policy Optimization*, PPO. O *DyNA PPO* modela o problema do design de proteínas como um processo de decisão de Markov, onde um agente gera sequências de aminoácidos de forma autoregressiva, adicionando resíduos um por um. A função de recompensa é baseada em métricas de estabilidade estrutural e funcionalidade da proteína, sendo calculada apenas ao final da geração da sequência. Esse mecanismo permite que o modelo aprenda estratégias eficazes para explorar o espaço de sequências de forma eficiente. O modelo é treinado iterativamente, ajustando sua política para maximizar a recompensa acumulada. Durante o treinamento, um conjunto de redes neurais auxiliares avalia a qualidade das sequências geradas, fornecendo sinais de aprendizado ao agente. Embora o *DyNA PPO* tenha demonstrado resultados promissores em benchmarks computacionais, sua validação experimental ainda está em aberto.

A análise da literatura existente evidencia que o design computacional de proteínas tem avançado significativamente, impulsionado por metodologias como modelagem molecular baseada em física, aprendizado profundo e aprendizado por reforço. Modelos como *AlphaFold*, *Rosetta*, *ESMFold* e *ProteinMPNN* têm contribuído de forma expressiva para a predição estrutural e o *design* de sequências proteicas. Além disso, técnicas de aprendizado por reforço, como *DyNA PPO*, demonstraram grande potencial para a otimização de sequências proteicas, explorando o espaço conformacional de maneira adaptativa e eficiente.

No entanto, não foram encontrados estudos que apliquem aprendizado por reforço especificamente para a otimização do FIX no tratamento da hemofilia B. A pesquisa realizada não identificou publicações que abordem a aplicação dessa abordagem para modificar ou aprimorar a sequência do FIX, de modo a aumentar sua estabilidade ou reduzir sua imunogenicidade como proposto pelo presente trabalho.

Capítulo 3

Fundamentação teórica

Neste capítulo vamos apresentar os fundamentos teóricos utilizados neste trabalho acerca de proteínas e aprendizado por reforço profundo.

3.1 Proteína

Uma proteína é uma macromolécula biológica composta por cadeias de aminoácidos. Constituem a maior parte da massa seca de uma célula, podendo desempenhar funções enzimáticas, estruturais, imunológicas, de transporte, entre outras (PETER WALTER, 2002).

Existem milhares de proteínas diferentes em uma célula, onde cada uma é composta por uma sequência distinta dos 20 tipos de aminoácidos encontrados na natureza, unidos através de ligações peptídicas. Por conta disto, as proteínas são também conhecidas como polipeptídeos (PETER WALTER, 2002).

A cadeia polipeptídica é composta por três componentes: a cadeia principal, as cadeias laterais e as ligações peptídicas. A cadeia principal é também referida como o esqueleto da proteína e é definida como uma série repetitiva e encadeada de átomos de carbono, nitrogénio e oxigénio. Anexadas a cadeia principal, encontram-se as cadeias laterais. Estas não estão envolvidas nas ligações peptídicas e são responsáveis por caracterizar as principais propriedades da proteína PETER WALTER, 2002.

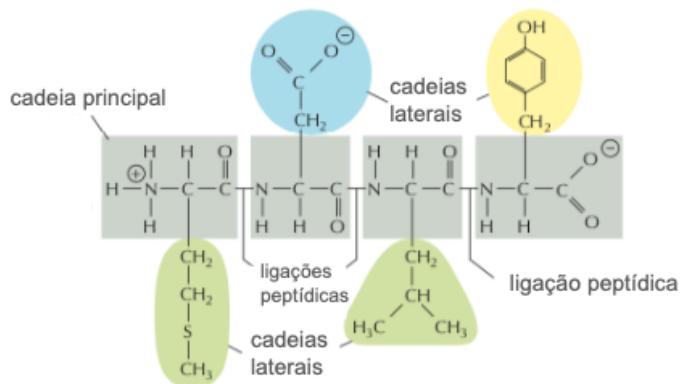


Figura 3.1: Componentes de uma proteína

Aminoácido	Cadeia lateral	Aminoácido	Cadeia lateral
Aspartic acid	Asp D negative	Alanine	Ala A nonpolar
Glutamic acid	Glu E negative	Glycine	Gly G nonpolar
Arginine	Arg R positive	Valine	Val V nonpolar
Lysine	Lys K positive	Leucine	Leu L nonpolar
Histidine	His H positive	Isoleucine	Ile I nonpolar
Asparagine	Asn N uncharged polar	Proline	Pro P nonpolar
Glutamine	Gln Q uncharged polar	Phenylalanine	Phe F nonpolar
Serine	Ser S uncharged polar	Methionine	Met M nonpolar
Threonine	Thr T uncharged polar	Tryptophan	Trp W nonpolar
Tyrosine	Tyr Y uncharged polar	Cysteine	Cys C nonpolar

Aminoácidos polares Aminoácidos apolares

Figura 3.2: Cada aminoácido tem uma abreviação de uma ou três letras - figura 3-2 adaptada PETER WALTER, 2002.

3.1.1 Estrutura proteíca

A função de uma proteína está intimamente relacionada à sua estrutura tridimensional, que é formada principalmente a partir das interações entre as cadeias laterais e moléculas encontradas no meio físico ao qual a proteína está inserida. Devido a essas interações, a maioria das proteínas assume uma estrutura tridimensional única, que é determinada pela ordem dos aminoácidos na sequência. A conformação final tende a ser aquela que possui a menor energia livre (PETER WALTER, 2002). Por energia livre entende-se como à energia potencial total do sistema molecular que inclui a proteína e seu meio circundante. Essa energia é uma medida termodinâmica que combina componentes de energia entálpica (relacionada a ligações químicas e interações eletrostáticas) e entropia (relacionada à desordem ou ao número de configurações possíveis das moléculas).

PETER WALTER, 2002 explica que a polaridade das cadeias laterais desempenham um papel importante na predição estrutural da proteína. As cadeias não polares (hidrofóbicas) tendem a se agrupar no interior da molécula, evitando contato com a água. Já as polares tendem a se dispor perto da superfície da molécula, onde podem formar ligações de hidrogênio com a água e outras moléculas polares.

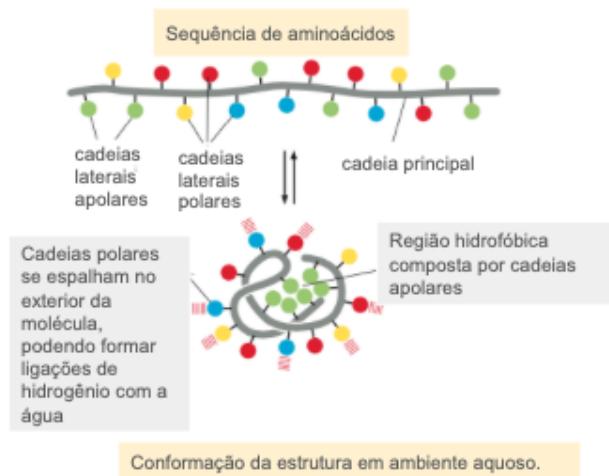


Figura 3.3: Exemplo de conformação protéica PETER WALTER, 2002 - adaptado

3.1.2 O Fator IX

O Fator IX (FIX) é uma proteína essencial para o processo de coagulação. Quando ativado (FIXa), atua em conjunto com o Fator VIIIa (FVIIIa) para formar um complexo conhecido como tenase intrínseco, que é responsável por ativar o Fator X. Este processo é fundamental para a geração de trombina e formação de coágulos (DIEST E DOUGALD M. MONROE, 2024). A ausência ou disfunção do FIX compromete o processo de ativação do FX, impossibilitando uma coagulação saudável, o que configura a hemofilia tipo B.

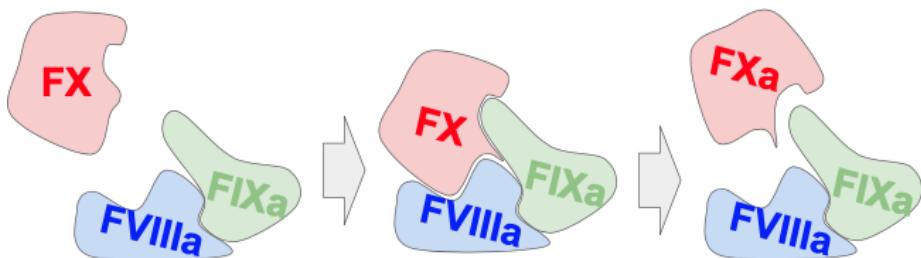


Figura 3.4: Atuação do FIXa na ativação do FX

O FIXa é composto por diferentes domínios, cada um desempenhando um papel essencial nas interações moleculares que permitem a formação do complexo tenase intrínseco. Na região N-terminal, o domínio Gla (gamma-carboxiglutâmico) é responsável por ligar o FIXa a superfícies de membranas fosfolipídicas, uma interação dependente de íons de cálcio, fundamental para posicionar o complexo de coagulação no local da lesão vascular (DIEST E DOUGALD M. MONROE, 2024). Os domínios de fator de crescimento epidérmico (EGF1 e EGF2) desempenham funções complementares: o EGF1 facilita o reconhecimento de cofatores e substratos, enquanto o EGF2 interage com o domínio A3 do Fator VIIIa, contribuindo para a montagem do complexo tenase (DIEST E DOUGALD M. MONROE, 2024). O papel mais crítico para a estabilidade e a funcionalidade do complexo tenase reside no

domínio protease, cuja interação com o domínio A2 do FVIIIa permite a ativação conformational necessária para uma catálise eficiente do FX. DIEST E DOUGALD M. MONROE, 2024 explica que variantes do FIXa, como o FIX-Padua, que modificam o domínio protease, apresentam maior eficiência catalítica, destacando seu papel central no desenvolvimento de proteínas otimizadas para terapia de hemofilia.

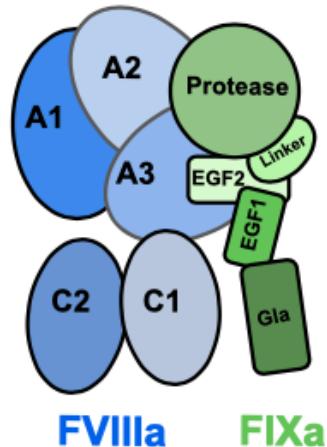


Figura 3.5: Interação entre FIXa e FVIIIa, formando o complexo tenase. Adaptação da figura 3 de DIEST E DOUGALD M. MONROE, 2024

A estrutura do domínio protease é a estrutura alvo do *pipeline de sequence design* proposto por este trabalho. É composta por 235 resíduos. Logo, o espaço de possíveis novas sequências com este tamanho, considerando 20 diferentes aminoácidos, é de 235^{20} .



Figura 3.6: Estrutura alvo - Domínio protease do Fator IXa

As proteínas projetadas neste estudo serão desenvolvidas para mimetizar a estrutura do domínio protease. O objetivo é identificar, entre as variantes geradas, aquelas capazes de estabelecer interações mais estáveis com o FVIIIa, aprimorando a estabilidade do complexo tenase intrínseco. Adicionalmente, espera-se que as novas estruturas apresentem um perfil

imunogênico reduzido em comparação ao FIXa nativo, contribuindo para maior segurança e eficácia terapêutica.

3.1.3 Docking

A análise de *docking* é uma técnica computacional amplamente utilizada no estudo de interações biomoleculares, particularmente para prever a orientação e a afinidade entre duas moléculas, como proteínas. Nesse sentido, é essencial para avaliar como uma proteína substituta do FIXa interage com o FVIIIa. O *docking* molecular simula o reconhecimento entre uma molécula receptora e outra ligante. No caso de interações proteína-proteína, o receptor e o ligante são ambos macromoléculas, cujas superfícies e conformações influenciam a formação de um complexo estável. O objetivo do *docking* é identificar as poses mais favoráveis termodinamicamente, ou seja, aquelas que minimizam a energia livre do sistema.

Durante o *docking*, diversas poses do ligante em relação ao receptor são geradas. Ferramentas como RosettaDock ou AutoDock realizam essa busca, explorando translações, rotações e flexibilidade local. Cada pose é avaliada com base em métricas energéticas, como a *Contact Molecular Surface* (CMS), *Interface Buried SASA* (IBSASA), *Delta Gibbs Free Energy of Binding* (DDG) e *Spatial Aggregation Propensity Score* (SAP Score).

A CMS é uma medida desenvolvida para superar as limitações de métricas tradicionais, como *Shape Complementarity* (SC) e *Delta Solvent Accessible Surface Area* (Delta SASA) (COVENTRY, 2021). Enquanto SC analisa a complementaridade geométrica entre superfícies moleculares e Delta SASA calcula a área de superfície acessível ao solvente antes e depois da complexação, ambas possuem limitações na identificação de interfaces bem empacotadas (COVENTRY, 2021). Em contraste, o CMS combina a área de contato com um fator de penalização baseado na distância entre triângulos de superfície, oferecendo uma representação mais precisa da qualidade do empacotamento na interface (COVENTRY, 2021).

A IBSASA é frequentemente usada para estimar a extensão de área de superfície enterrada durante a formação de um complexo proteico, correlacionando-se com a estabilidade de ligação. No entanto, sozinha, essa métrica pode ser enganosa em interfaces mal organizadas, onde grandes áreas de contato podem não resultar em interações eficazes (COVENTRY, 2021).

Por outro lado, a DDG fornece uma medida direta do quanto favorável energeticamente é uma interação, com valores mais negativos indicando maior estabilidade termodinâmica (COVENTRY, 2021). A DDG, calculada frequentemente com o software Rosetta, permite a otimização de sequências e conformações para maximizar a energia de ligação.

Por fim, o SAP Score avalia a presença de regiões hidrofóbicas expostas na superfície da proteína, utilizando a área de superfície acessível ao solvente (SASA) como referência. A partir dessa análise, estima-se a propensão da proteína ou do complexo formado à agregação indesejada. Valores mais baixos de SAP indicam menor exposição de patches hidrofóbicos ao solvente, sugerindo maior estabilidade estrutural e menor risco de agregação, o que é desejável na formação de complexos moleculares estáveis (COVENTRY, 2021).

3.1.4 Resposta Imunológica

A resposta imune desencadeada por uma proteína terapêutica é um fator crítico que pode influenciar diretamente sua segurança e eficácia. No contexto de *sequence design* de uma proteína substituta do FIXa, a análise dessa resposta imune é especialmente relevante para evitar complicações associadas à formação de inibidores, uma limitação comum no tratamento de hemofilia. Esses inibidores são anticorpos neutralizantes que se ligam à proteína administrada, reduzindo sua eficácia e exigindo estratégias de tratamento alternativas mais caras e menos seguras.

A imunogenicidade está intrinsecamente relacionada à presença de epítópos imunogênicos na sequência da proteína. Esses epítópos são regiões específicas que se ligam a moléculas de MHC classe II em células que apresentam抗ígenos (APCs), facilitando a ativação de linfócitos T auxiliares (ALESSANDRO SETTE, 2020). A afinidade de ligação é um fator determinante na indução da resposta imune. Altas afinidades entre peptídeos e MHC-II aumentam a probabilidade de reconhecimento imune e subsequente ativação de células T (ALESSANDRO SETTE, 2020).

A predição de afinidade de ligação entre epítópos e MHC-II emprega ferramentas computacionais baseadas em aprendizado de máquina, como o NetMHCIIpan, que simulam interações entre peptídeos derivados da proteína e uma variedade de alelos de MHC. A sequência da proteína é fragmentada em peptídeos sobrepostos com comprimentos típicos de 8 a 15 aminoácidos, e a afinidade de cada peptídeo é quantificada por meio do valor de IC_{50} (concentração inibitória de 50%). Peptídeos com valores de IC_{50} baixos ($(IC_{50} < 50 \text{ nM})$) indicam maior afinidade de ligação e, portanto, são mais propensos a serem reconhecidos como epítópos imunogênicos (ALESSANDRO SETTE, 2020).

Portanto, o objetivo ao projetar a proteína substituta do FIXa é não apenas otimizar a estabilidade de ligação ao FVIIIa, mas também evitar a apresentação de novos epítópos imunogênicos que poderiam levar à formação de inibidores. A redução da imunogenicidade melhora a adesão ao tratamento e reduz complicações, consolidando a importância da integração de previsões imunológicas no *pipeline* de desenvolvimento de proteínas terapêuticas.

3.1.5 Mutação

Uma mutação no contexto de proteínas refere-se a uma modificação na sequência de aminoácidos. Por menor que seja esta modificação, a mutação pode acarretar em uma alteração na estrutura tridimensional da proteína, uma vez que a ordem que os aminoácidos estão dispostos na sequência influencia diretamente na conformação da estrutura. Neste trabalho, vamos assumir que uma mutação consiste na substituição de apenas um aminoácido por outro na sequência.

3.1.6 Similariedade entre estruturas

Para projetar proteínas semelhantes ao FIXa, é necessário definir uma métrica de similaridade entre estruturas. Duas métricas amplamente utilizadas são o *Root-Mean-Square Deviation* (RMSD) e o *Template Modeling Score* (TMScore) (JEFFREY SKOLNICK, 2004),

cada uma com características próprias que influenciam sua adequação a diferentes cenários de comparação estrutural.

O **RMSD** é definido como a raiz quadrada da média dos quadrados das distâncias entre pares de átomos correspondentes em duas estruturas alinhadas:

$$\text{RMSD} = \sqrt{\frac{1}{N} \sum_{i=1}^N d_i^2}, \quad (3.1)$$

Onde N representa o número de pares de átomos alinhados e d_i é a distância entre os i -ésimos átomos nas estruturas comparadas. Embora seja uma métrica intuitiva, o RMSD é altamente sensível a desalinhamentos locais e não é normalizado pelo comprimento da proteína, o que limita sua eficácia ao comparar proteínas de diferentes tamanhos.

O **TMScore**, por sua vez, mede a similaridade estrutural global, superando limitações do RMSD. **JEFFREY SKOLNICK, 2004** a formulou da seguinte maneira:

$$\text{TMScore} = \frac{1}{L_{\text{ref}}} \sum_{i=1}^{L_{\text{model}}} \frac{1}{1 + \left(\frac{d_i}{d_0(L_{\text{ref}})} \right)^2}, \quad (3.2)$$

Onde L_{ref} é o número de resíduos na estrutura de referência, L_{model} é o número de resíduos no modelo comparado, e d_i é a distância entre os átomos C_α alinhados.

JEFFREY SKOLNICK, 2004 define d_0 em função de L_{ref} da seguinte maneira:

$$d_0(L_{\text{ref}}) = 1.24 \times (L_{\text{ref}} - 15)^{1/3} - 1.8. \quad (3.3)$$

Este parâmetro adapta a escala de distâncias consideradas significativas para o alinhamento estrutural, ajustando-se ao comprimento da proteína de referência, L_{ref} . O termo $(L_{\text{ref}} - 15)^{1/3}$ reflete uma relação empírica entre o tamanho da proteína e as distâncias típicas entre resíduos alinhados, modelando o crescimento da distância permissível conforme a proteína aumenta de tamanho. A constante multiplicativa 1.24 e o deslocamento -1.8 também foram determinados empiricamente para fornecer um valor de d_0 que otimiza a correlação entre o TMScore e a percepção biológica de similaridade estrutural. Essa função adapta o limiar de normalização das distâncias entre pares de resíduos alinhados, garantindo que proteínas de diferentes comprimentos sejam comparadas de forma justa. Proteínas maiores toleram distâncias absolutas maiores entre resíduos alinhados sem que o TMScore seja severamente penalizado (**JEFFREY SKOLNICK, 2004**).

O **TMScore** varia entre 0 e 1, onde valores próximos a 1 indicam alta similaridade topológica (**JEFFREY SKOLNICK, 2004**). Se a distância entre cada par alinhado de átomos C_α for igual a 0, então o TMScore é igual a 1, indicando sobreposição completa entre as macromoléculas. Em contra partida, quanto maiores são as distâncias, menor é o TMScore (mais próximo de 0).

Devido à sua robustez na avaliação da similaridade estrutural global e à sua interpreta-

bilidade, com valores limitados entre 0 e 1, adotaremos o TMScore como a métrica principal a ser otimizada neste projeto. O cálculo desta medida será feito a partir da plataforma *US-align* desenvolvida por (YANG ZHANG, 2022).

3.1.7 Conservation Score

O *Conservation Score* (CS) é uma métrica que estima a importância ou contribuição individual de cada resíduo da sequência na caracterização da estrutura da proteína. Resíduos cruciais na estrutura da proteína tendem a ser conservados, visto que alterações neles podem impactar significativamente a função proteíca (RIOS RICARDO, 2022). O score é obtido levando-se em conta a frequência com que certas combinações de aminoácidos ocorrem em proteínas homólogas ao longo da evolução das espécies (EDDY, 2004). Para este trabalho, utilizamos o CS calculado pelo servidor ConsurfDB (ADI BEN CHORIN, 2020), tendo a estrutura do FIXa de coagulação como entrada.



Figura 3.7: A maior parte dos resíduos do FIXa possuem um baixo CS. Os maiores valores estão concentrados em cerca de 12 resíduos espalhados ao longo da sequência.

A identificação de posições conservadas é um aspecto fundamental ao projetar novas proteínas, pois fornece informações essenciais para evitar mutações em regiões críticas, preservando assim a estabilidade estrutural e a função biológica da molécula.

3.1.8 Similariedade entre aminoácidos

Da mesma forma que regiões com altos score de conservação devem ser evitadas, convém evitar mutações que substituem aminoácidos muito diferentes. Nesse sentido, para mensurar o nível de similaridade entre os aminoácidos, utilizamos uma métrica de distância fundamentada no trabalho de RIOS RICARDO, 2021, que propõe uma abordagem vetorial para representar as propriedades de cada aminoácido. Nesse estudo, cada aminoácido foi descrito por um vetor de 544 dimensões, incorporando uma ampla gama de características físico-químicas e estruturais. A construção desses vetores foi realizada com o auxílio do pacote seqinR (CHARIF, 2007), uma ferramenta especializada em análise de sequências biológicas. O pacote seqinR utiliza uma base de dados abrangente contendo propriedades como peso molecular, hidrofobicidade, polaridade, acessibilidade à superfície, entre outras, para derivar descriptores numéricos que caracterizam as propriedades de cada aminoácido.

A partir dessa representação, RIOS RICARDO, 2021 introduziu uma matriz de distâncias, construída a partir das distâncias euclidianas de cada par de vetores, fornecendo uma

medida quantitativa da dissimilaridade entre aminoácidos.

	A	C	D	E	F	G	H	I	K	L	M	N	P	Q	R	S	T	V	W	Y
A	0	1.5	1.57	1.51	1.52	1.59	1.51	1.52	1.52	1.46	1.48	1.51	1.49	1.47	1.6	1.38	1.49	1.44	1.55	1.59
C	1.5	0	1.6	1.54	1.48	1.68	1.51	1.46	1.61	1.49	1.48	1.59	1.34	1.5	1.61	1.53	1.54	1.42	1.57	1.56
D	1.57	1.6	0	1.48	1.65	1.61	1.55	1.62	1.59	1.67	1.65	1.51	1.46	1.53	1.63	1.52	1.58	1.6	1.72	1.62
E	1.51	1.54	1.48	0	1.62	1.63	1.53	1.6	1.58	1.63	1.58	1.5	1.51	1.47	1.61	1.56	1.58	1.57	1.7	1.63
F	1.52	1.48	1.65	1.62	0	1.63	1.48	1.39	1.61	1.45	1.48	1.56	1.6	1.54	1.61	1.58	1.52	1.42	1.53	1.49
G	1.59	1.68	1.61	1.63	1.63	0	1.58	1.6	1.57	1.65	1.68	1.53	1.47	1.57	1.59	1.54	1.62	1.57	1.77	1.59
H	1.51	1.51	1.55	1.53	1.48	1.58	0	1.49	1.51	1.52	1.46	1.48	1.44	1.46	1.52	1.51	1.54	1.47	1.62	1.5
I	1.52	1.46	1.62	1.6	1.39	1.6	1.49	0	1.58	1.42	1.42	1.5	1.58	1.51	1.57	1.57	1.53	1.14	1.55	1.45
K	1.52	1.61	1.59	1.58	1.61	1.57	1.51	1.58	0	1.59	1.61	1.48	1.54	1.45	1.49	1.44	1.49	1.55	1.65	1.56
L	1.46	1.49	1.67	1.63	1.45	1.65	1.52	1.42	1.59	0	1.5	1.58	1.64	1.56	1.62	1.47	1.52	1.43	1.53	1.54
M	1.48	1.48	1.65	1.58	1.48	1.68	1.46	1.42	1.61	1.5	0	1.62	1.55	1.52	1.65	1.6	1.6	1.48	1.57	1.57
N	1.51	1.59	1.51	1.5	1.56	1.53	1.48	1.5	1.48	1.58	1.62	0	1.4	1.45	1.52	1.35	1.49	1.56	1.62	1.54
P	1.49	1.34	1.46	1.51	1.6	1.47	1.44	1.58	1.54	1.64	1.55	1.4	0	1.45	1.57	1.38	1.46	1.55	1.65	1.58
Q	1.47	1.5	1.53	1.47	1.54	1.57	1.46	1.51	1.45	1.56	1.52	1.45	1.45	0	1.52	1.43	1.44	1.49	1.59	1.53
R	1.6	1.61	1.63	1.61	1.61	1.59	1.52	1.57	1.49	1.62	1.65	1.52	1.57	1.52	0	1.53	1.56	1.51	1.73	1.55
S	1.38	1.53	1.52	1.56	1.58	1.54	1.51	1.57	1.44	1.47	1.6	1.35	1.38	1.43	1.53	0	1.21	1.49	1.55	1.5
T	1.49	1.54	1.58	1.58	1.52	1.62	1.54	1.53	1.49	1.52	1.6	1.49	1.46	1.44	1.56	1.21	0	1.43	1.53	1.56
V	1.44	1.42	1.6	1.57	1.42	1.57	1.47	1.14	1.55	1.43	1.48	1.56	1.55	1.49	1.51	1.49	1.43	0	1.59	1.4
W	1.55	1.57	1.72	1.7	1.53	1.77	1.62	1.55	1.65	1.53	1.57	1.62	1.65	1.59	1.73	1.55	1.53	1.59	0	1.59
Y	1.59	1.56	1.62	1.63	1.49	1.59	1.5	1.45	1.56	1.54	1.57	1.54	1.58	1.53	1.55	1.5	1.56	1.4	1.59	0

Figura 3.8: Distâncias entre pares de aminoácidos *RIOS RICARDO, 2021*

3.2 Aprendizado por reforço profundo

Nesta seção vamos introduzir os conceitos envolvidos no aprendizado por reforço profundo, que formam a base teórica da técnica que iremos utilizar: Proximal Policy Optimization (PPO). Para tal, será fornecido um contexto sobre Processo de Decisão de Markov (MDP), Redes Neurais (NN) e o método Ator-Crítico (AC).

3.2.1 Processo de Decisão de Markov

O Processo de Decisão de Markov (MDP) é utilizado para modelar processos de forma probabilística. Ele é chamado de markoviano pois a distribuição de probabilidade de um estado depende apenas do estado anterior e da ação selecionada. Uma ação dá origem a um novo estado ao passo que promove alterações no estado atual. Um agente seleciona cada ação com base em uma política (π) que mapeia estados a ações. Em um MDP, o processo evolui em etapas, ou *steps*, à medida que o agente toma ações. A sequência de estados, desde o inicial até o final, é chamada de episódio. A qualidade de cada ação é avaliada com base no quanto benéfico é o estado alcançado. De acordo com *PELLEGRINI, 2007*, o MDP pode ser definido como uma tupla $\langle S, A, T, R \rangle$ onde:

- S é o conjunto de possíveis estados;
- A é o conjunto de ações que interferem no processo;
- T : $S \times A \times S \rightarrow [0,1]$ é uma função que quantifica a probabilidade de mudança do estado $s \in S$ para o estado $s' \in S$, dado a ação $a \in A$ selecionada. É representado por $T(s'|s, a)$;

- $r : S \times A \rightarrow r$ é uma função que mede a recompensa por selecionar a ação $a \in A$ quando o processo está no estado $s \in S$.

De modo a encontrar uma boa política π , é necessário definir uma maneira de comparar diferentes políticas. Uma técnica comum é comparar a esperança da recompensa acumulada descontada, ou Valor de Retorno (R), que cada política produziu em um mesmo episódio.

$$R = E \left[\sum_{k=1}^z \gamma^{k-1} r_k \right] \quad (3.4)$$

Sendo z o tamanho do episódio, k o índice do *step* e o r_k a recompensa obtida em k . A constante γ é um valor entre 0 e 1, chamado de fator de desconto. Ele é responsável por atribuir um peso maior a recompensas obtidas no início do episódio.

Além disso, existem outras duas métricas importantes para se avaliar a qualidade de uma política: a Função de Valor (V) e a função de Valor da Ação (Q). A primeira estima a vantagem de estar em um estado s , calculando a esperança de R dado o estado inicial $s_0 = s$.

$$V_\pi(s) = E[R|s_0 = s] \quad (3.5)$$

A segunda estima a vantagem de selecionar a ação a estando no estado s . Em outras palavras, é definida como a esperança de R dado o estado inicial e a ação inicial:

$$Q_\pi(s, a) = E[R|s_0 = s, a_0 = a] \quad (3.6)$$

Neste trabalho vamos modelar tanto a política π quanto a Função de Valor V utilizando redes neurais profundas.

3.2.2 Redes Neurais

Inspirado no sistema neural humano, uma rede neural artificial consiste em um conjunto de nós, chamados de neurônios, interconectados por arestas (BISHOP, 2006). Em geral, é organizada em camadas, que incluem três tipos: a camada de entrada, a camada oculta e a camada de saída, conforme ilustrado na figura 3.9.

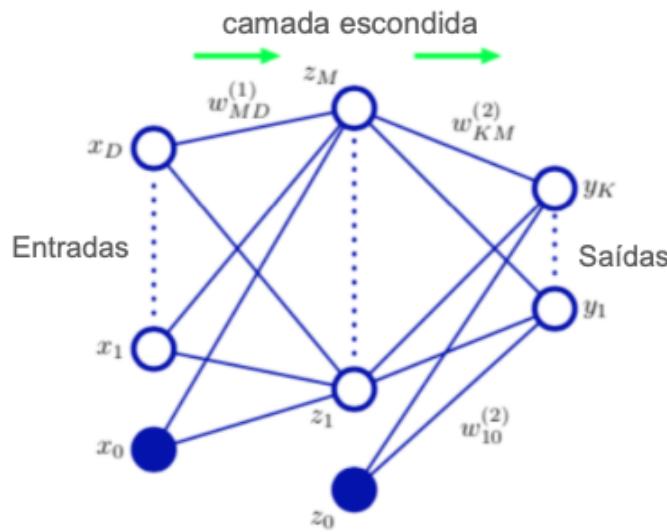


Figura 3.9: Arquitetura de uma rede neural - BISHOP, 2006 adaptado

Sinais fluem entre os neurônios através das arestas que estão associadas a um peso (w) que quantifica a sua importância. Nos neurônios é feito o processamento dos diversos sinais recebidos que, em seguida, aplica-se uma função, conhecida como função de ativação. Esta pode ser simplesmente uma combinação linear das entradas ponderadas pelos seus respectivos pesos, como pode ser função não linear como sigmoid, tangente hiperbólica, entre outras (BISHOP, 2006).

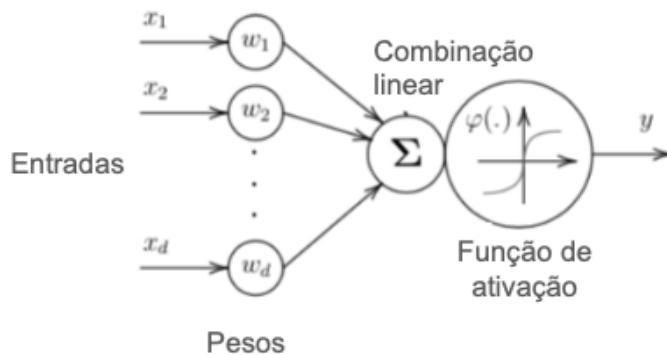


Figura 3.10: Neurônio processando sinal FIGUEIREDO, 2018

Os pesos das arestas são ajustados durante a fase de treinamento, de modo a orientar a rede a produzir a saída esperada para uma entrada específica. Nesta fase, é aplicado uma função de perda baseado na saída da rede. Existem diversas técnicas possíveis para minimizar a função de perda. Dentre elas, uma das mais tradicionais é a baseada no gradiente descendente, que atualiza os pesos conforme a equação a seguir.

$$w(t+1) = w(t) - n \nabla L(w(t)) \quad (3.7)$$

Onde w é o vetor de pesos, n é uma constante positiva conhecida como taxa de aprendizagem, que quantifica o tamanho do ajuste dos parâmetros a cada iteração e L é a função de perda. Um dos algoritmo mais utilizados para calcular o gradiente da função de perda e atualizar os parâmetros da rede é o *Backpropagation* (BISHOP, 2006).

No contexto deste trabalho, as funções de perda estarão fortemente relacionadas ao valor de Retorno R e a função de Valor V apresentadas na seção anterior.

3.2.3 Método Actor-Critic

O método Ator-Crítico (AC) é um procedimento que tem como objetivo otimizar a política de um MDP (JOHN N. TSITSIKLIS, 2001). Ele é composto por dois componentes principais: o Ator e o Crítico. O Ator é aquele que seleciona as ações baseado nos estados, i.e, desempenha a função da política em um MDP. O Crítico, como o nome sugere, avalia a ação selecionada pelo Ator, estimando o vantagem de estar no estado alcançado. Assim, o Crítico é representado pela função de Valor do MDP. Tanto o Ator quanto o Crítico serão estimados por uma rede neural profunda cujos parâmetros serão ajustados utilizando a técnica *Proximal Policy Optimization* (OLEG KLIMOV, 2017).

3.2.4 PPO

A técnica *Proximal Policy Optimization* é um modelo de aprendizado por reforço profundo que define funções de perda para ajustar os pesos das redes neurais pertencentes à arquitetura do método AC (OLEG KLIMOV, 2017).

Uma vez que o Crítico objetiva estimar o valor de V, o ajuste dos seus parâmetros (W) é feito através de um gradiente descendente a fim de minimizar o quadrado da diferença entre a saída da rede ($\hat{V}(W)$) e o V observado (V^{obs}) OLEG KLIMOV, 2017:

$$L_t^{VF}(W) = (\hat{V}_t(W) - V_t^{obs})^2 \quad (3.8)$$

Uma das principais motivações do PPO é, durante o processo de otimização do MDP, evitar atualizações de política muito grandes. Para isto, OLEG KLIMOV, 2017 força com que a razão entre a política atual e a política anterior ($r_t(\Theta)$) seja limitada a um intervalo conveniente.

$$r_t(\Theta) = \frac{\pi_\Theta}{\pi_{\Theta old}} \quad (3.9)$$

Desta forma, para ajustar os parâmetros (Θ) do Ator, OLEG KLIMOV, 2017 define a seguinte função objetivo a ser maximizada por um gradiente ascendente:

$$L^{CLIP}(\Theta) = \hat{E}_t[min(r_t(\Theta)\hat{A}_t, clip(r_t(\Theta), 1 - \epsilon, 1 + \epsilon)\hat{A}_t)] \quad (3.10)$$

Onde ϵ é uma constante que o OLEG KLIMOV, 2017 sugere ser igual a 0.2. \hat{A}_t é definido como a estimativa da função de vantagem, que corresponde ao benefício de selecionar

uma ação a no estado s , em comparação com uma seleção aleatória de uma ação no estado s . Em outras palavras, é a diferença entre Q e V :

$$A = Q(s, a) - V(s) \quad (3.11)$$

A função objetivo $L^{CLIP}(\Theta)$ é a esperança do mínimo de dois termos: $r_t(\Theta)\hat{A}_t$ e $\text{clip}(r_t(\Theta), 1-\epsilon, 1+\epsilon)\hat{A}_t$. O primeiro direciona a política a selecionar ações que maximizam a função de vantagem. O segundo é uma versão truncada do primeiro, onde é aplicado um *clip* no $r_t(\Theta)$ de modo a garantir que a nova política não se distancie muito da política anterior.

Uma vez que o aprendizado das redes do AC são dependentes entre si, [OLEG KLIMOV, 2017](#) sugere uma função objetivo única para treinar ambos:

$$L_t^{PPO}(\Theta) = \hat{E}_t[L_t^{CLIP}(\Theta) - c_1 L_t^{VF}(\Theta) + c_2 S(s_t)] \quad (3.12)$$

Onde c_1 e c_2 são constantes e S é definido por [OLEG KLIMOV, 2017](#) como um bônus de entropia que garante que o agente explore suficientemente o ambiente durante o treinamento.

3.2.5 Escalonamento Multidimensional (MDS)

O uso de técnicas de redução de dimensionalidade, como o *Metric Multidimensional Scaling* (MDS), é motivado pela necessidade de construir representações vetoriais de objetos em um espaço de menor dimensão, preservando as distâncias definidas em uma matriz de similaridade ou dissimilaridade. No contexto deste trabalho, utilizamos o MDS para gerar uma representação vetorial para cada aminoácido, respeitando as distâncias previamente definidas na matriz proposta por [RIOS RICARDO, 2021](#). Esta abordagem permite incorporar relações complexas de similaridade em uma forma compatível com métodos de aprendizado de máquina e análise estrutural.

Dado um conjunto de n objetos e uma matriz de distâncias $D = (d_{ij})$, onde cada elemento d_{ij} representa a distância entre o par de objetos i e j , o objetivo do MDS é encontrar uma configuração vetorial $X_i = [x_{i1}, x_{i2}, \dots, x_{im}]$ para cada objeto i em um espaço de dimensão m , de modo que a distância euclidiana entre dois objetos i, j dados respectivamente pelas suas representações X_i e X_j aproxime d_{ij} . O MDS busca minimizar as distâncias reais e as distâncias no espaço embutido, utilizando a função de perda conhecida como *stress*:

$$\text{Stress}(X_1, X_2, \dots, X_n) = \sqrt{\sum_{i \neq j=1}^n (d_{ij} - \|X_i - X_j\|)^2}. \quad (3.13)$$

A minimização desta função é geralmente realizada pelo algoritmo SMACOF (*Scaling by MAjorizing a Complicated Function*), que iterativamente melhora a configuração de pontos em direção a uma solução de menor *stress*, garantindo uma melhor correspondência

entre as distâncias calculadas e as observadas (KRUSKAL, 1964). Embora outros métodos, como o gradiente descendente, possam ser utilizados, o SMACOF é amplamente preferido devido à sua eficiência e estabilidade.

Neste trabalho, a implementação do MDS foi realizada utilizando a biblioteca `sklearn`, que fornece uma solução eficiente para problemas de escala multidimensional, baseada nas técnicas originalmente propostas por KRUSKAL, 1964.

Capítulo 4

Metodologia

Neste capítulo especificamos os métodos e as técnicas utilizadas para responder se é possível, através de *Sequence Design*, projetar uma proteína que desempenhe a mesma função do FIX, mas com maior estabilidade e menor imunogenicidade. Para responder a esta pergunta, foram estabelecidos os seguintes objetivos:

1. Desenvolver um *pipeline* genérico que produza sequências que mimetizem uma estrutura qualquer.
2. Obter um conjunto de sequências de aminoácidos que se conformam em estruturas similares ao FIX baseado na métrica *TMScore*.
3. Avaliar, dentro do conjunto de proteínas obtidas em 1, quais possuem potencial de substituir o FIX de modo tornar o tratamento de Hemofilia tipo B mais acessível e eficiente.

4.1 Estrutura do pipeline

De modo a atender os objetivos citados, propusemos um *pipeline* de *Sequence Design* genérico, cuja entrada é uma estrutura proteica alvo e a saída é um conjunto de sequências que mimetizam a estrutura de entrada.

A estrutura alvo utilizada é o domínio protease do FIX humano. O arquivo contendo as coordenadas tridimensionais dessa estrutura foi preparado em condições simuladas compatíveis com o ambiente fisiológico, isto é, meio aquoso, temperatura de 37 °C e pH neutro. Essa estrutura foi disponibilizada pelo trabalho de [RIOS RICARDO, 2022](#).

O *pipeline*, ilustrado na figura 4.1, foi implementado de forma modular, sendo composto por três módulos principais: Condições Iniciais; Treinamento e Geração de Sequências.

No módulo de Condições Iniciais obtemos a sequência inicial de aminoácidos utilizando o *ProteinMPNN*¹, adotado como heurística *H*. Esse modelo é uma rede neural profunda

¹Disponível em: <https://github.com/dauparas/ProteinMPNN/>

baseada em grafos, que recebe como entrada uma estrutura tridimensional e prediz a sequência mais provável de se conformar àquela estrutura, com base na orientação espacial dos átomos (J. D. e. AL, 2022). Definimos o *ProteinMPNN* como heurística por apresentar desempenho superior a métodos clássicos, como *Rosetta*, em diversas métricas de reconstrução de sequência a partir da estrutura, incluindo taxa de recuperação e viabilidade estrutural (J. D. e. AL, 2022).

No módulo de Treinamento, uma rede neural profunda, o *GenSeq*, é treinada para atuar como o Agente A, sendo capaz de realizar mutações que otimizam a similaridade com a estrutura alvo, isto é, o FIX. O *GenSeq* será treinado utilizando um algoritmo de aprendizado por reforço profundo, o *Proximal Policy Optimization* (PPO²) (OLEG KLIMOV, 2017). Para ser processada pela rede neural, a sequência de entrada é convertida em um vetor de *embeddings*, que é construído via MDS³ (*Multidimensional Scaling*) a partir da matriz de distâncias entre os aminoácidos, obtida a partir do trabalho de RIOS RICARDO, 2021, detalhado em 3.1.8.

O treinamento é realizado em dois estágios. No primeiro estágio o objetivo é restringir o espaço de ações do agente de modo a orientá-lo a evitar mutações em regiões altamente conservadas da sequência e substituições entre aminoácidos com perfis bioquímicos muito distintos. A função objetivo F_{obj} neste estágio é definida como uma relação entre o grau de conservação de cada posição na sequência — obtido a partir do trabalho de RIOS RICARDO, 2022 e detalhado em 3.1.7 — e a similaridade entre aminoácidos, medida com base em uma matriz de distâncias desenvolvida em RIOS RICARDO, 2021.

No segundo estágio, o *GenSeq* é orientado a realizar mutações que otimizam outra função objetivo: a similaridade entre a estrutura predita e a alvo. Para prever a estrutura tridimensional resultante de uma sequência mutada, utilizamos o *ESMFold*⁴, um modelo baseado em *transformers* capaz de realizar a predição de estruturas proteicas a partir de sequências de aminoácidos (Z. L. e. AL, 2022). Para viabilizar o *pipeline*, optamos por este modelo principalmente devido a sua elevada velocidade de predição, que é cerca de uma ordem de grandeza maior que outros modelos *benchmarking*, como o *AlphaFold* (Z. L. e. AL, 2022). A similaridade estrutural entre a estrutura predita e a estrutura alvo é avaliada com a métrica *TMScore*, selecionada por sua robustez na avaliação da similaridade estrutural global e por oferecer valores normalizados entre 0 e 1, o que facilita a interpretação dos resultados. O cálculo do *TMScore* é realizado por meio da plataforma *US-align* (YANG ZHANG, 2022).

Por fim, no módulo de Geração de Sequências, o agente treinado é utilizado para produzir um conjunto de variantes proteicas estruturalmente semelhantes ao FIX, por meio de um processo de mutação orientado. As sequências geradas são avaliadas para identificar candidatas viáveis a substituir o FIX no tratamento da hemofilia tipo B.

² Disponível em: <https://stable-baselines3.readthedocs.io/en/master/modules/ppo.html>

³ Disponível em: <https://scikit-learn.org/0.16/modules/generated/sklearn.manifold.MDS.html>

⁴ Modelo consumido via API: <https://api.esmatlas.com/foldSequence/v1/pdb/>

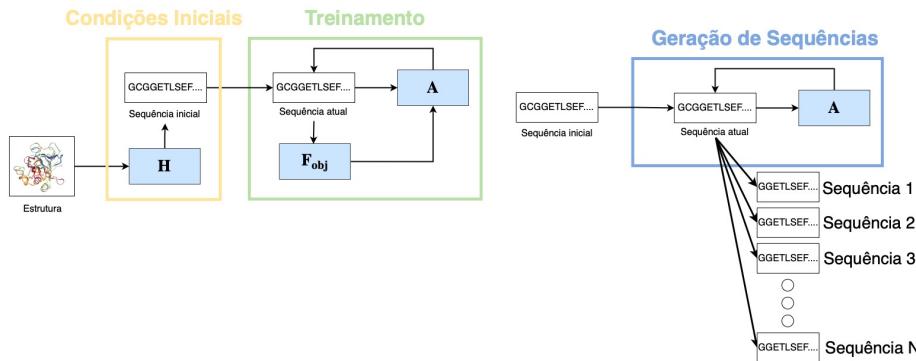


Figura 4.1: Pipeline proposto de Sequence Design.

4.2 Métodos de avaliação

A avaliação das proteínas geradas pelo agente é realizada em três etapas: análise estrutural, interação molecular por *Docking* e imunogenicidade. Cada etapa é essencial para verificar se as proteínas geradas possuem características estruturais, funcionais e imunológicas adequadas para substituir o FIX no tratamento da hemofilia B.

A primeira etapa consiste em medir a similaridade estrutural entre cada proteína gerada e o FIX por meio do *TMScore*. São selecionadas apenas proteínas com *TMScore* superior a 92%.

Na segunda etapa, avaliamos a capacidade das proteínas geradas de desempenhar a função do FIX, isto é, interagir com o Fator VIII (FVIII) e formar o complexo tenase, conforme descrito em 3.1.2. Assim como o FIX, o arquivo contendo as coordenadas tridimensionais do FVIII foi disponibilizada por [RIOS RICARDO, 2022](#) considerando meio aquoso, temperatura de 37 °C e pH neutro.

De modo a viabilizar a análise da iteração com o FVIII, é necessário alinhar estruturalmente a proteína gerada com o FVIII para garantir que a proteína mutante ocupe a mesma posição relativa do FIX no complexo original. Isso é feito utilizando *ChimeraX* (E. C. M. e. AL., 2023) por meio do comando `matchmaker`.

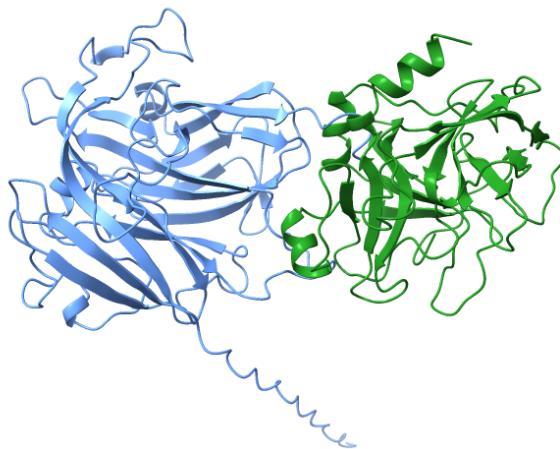


Figura 4.2: Proteína gerada 63 (verde) alinhada com o FVIII (azul)

Após o alinhamento estrutural, realizamos o *docking molecular* por meio do protocolo *Rosetta Docking*⁵, que permite prever a orientação e estabilidade do complexo proteína-proteína gerado. O *Rosetta Docking* consiste em um procedimento iterativo que busca a conformação de menor energia livre do complexo. O protocolo inicia com a geração de múltiplas poses, onde a proteína mutante é rotacionada e transladada em relação ao FVIII. Em seguida, as conformações passam por um refinamento energético que inclui otimização da orientação relativa (*rigid-body minimization*) e ajuste das cadeias laterais na interface (*side-chain minimization*). O protocolo utiliza a função de energia do *Rosetta* para estimar a estabilidade do complexo, considerando fatores como interações de *Van der Waals*, ligações de hidrogênio, energia eletrostática e solubilidade. Baseado na função de energia e da posição relativa dos átomos no complexo, é calculada as métricas *Contact Molecular Surface* (CMS), *Interface Buried SASA* (IBSASA), *Delta Gibbs Free Energy of Binding* (DDG) e *Surface Area Potential Score* (SAP Score), detalhadas em 3.1.3. A partir dessas métricas é possível avaliar de forma quantitativa se as proteínas geradas possuem uma interação favorável com o FVIII, ou seja, são capazes de desempenhar a função do FIX.

A terceira e última etapa de avaliação consiste na análise da imunogenicidade das proteínas geradas. O objetivo desta etapa é identificar possíveis epítópos imunogênicos presentes nas sequências, os quais poderiam desencadear respostas imunes indesejadas nos pacientes. Esses epítópos são regiões da sequência que se ligam a moléculas do Complexo Principal de Histocompatibilidade de classe II (MHC II) (vide 3.1.4). Para realizar esta análise, foi utilizado o *NetMHCIIpan* versão 4.1 (MASSIMO ANDREATTAS, 2018), algoritmo desenvolvido para predição de ligação de peptídeos a moléculas de MHC II. O *NetMHCIIpan* emprega técnicas de aprendizado de máquina para prever a afinidade de ligação de peptídeos derivados das proteínas analisadas às diferentes variantes alélicas de MHC II. Quanto mais peptídeos propensos a se ligar a alelos de MHC II, maior a probabilidade de desencadear uma resposta imune.

Para esta análise foram utilizados 46 alelos de MHC II frequentes na população humana,

⁵ Disponível em: https://docs.rosettacommons.org/docs/latest/application_documentation/docking/docking-protocol

4.2 | MÉTODOS DE AVALIAÇÃO

pertencentes aos grupos DP, DQ, DRB1 DRB3, DRB4 e DRB5. Estes alelos foram selecionados com o intuito de representar a diversidade populacional e garantir uma avaliação abrangente da imunogenicidade das variantes propostas.

O número total de epítópos fortes, a afinidade de ligação e a frequência com que os alelos ocorrem na natureza são as métricas utilizadas para avaliar e comparar a imunogenicidade das proteínas geradas com a proteína nativa.

Capítulo 5

Desenvolvimento do pipeline

Neste capítulo será detalhado como foram desenvolvidos os três módulos propostos na metodologia: Condições Iniciais, Treinamento e Geração de Sequências.

5.1 Condições iniciais

O objetivo do primeiro módulo (figura 5.1) é obter a sequência (S_{ini}) e o erro (Er_0) iniciais. A primeira é obtida ao se passar a estrutura alvo como entrada do *ProteinMPNN*. Já o erro inicial é definido pela seguinte expressão:

$$Er_0 = 1 - TMScore(E_{FIX}, E_{ini}) \quad (5.1)$$

Onde E_{FIX} é a estrutura alvo, i.e., a estrutura do fator IX de coagulação e E_{ini} é a estrutura vinculada a sequência inicial, predita pelo *ESMFold* - descrito em 2. O *TMScore* consiste em uma medida de similariedade entre estruturas, detalhada em 3.1.6

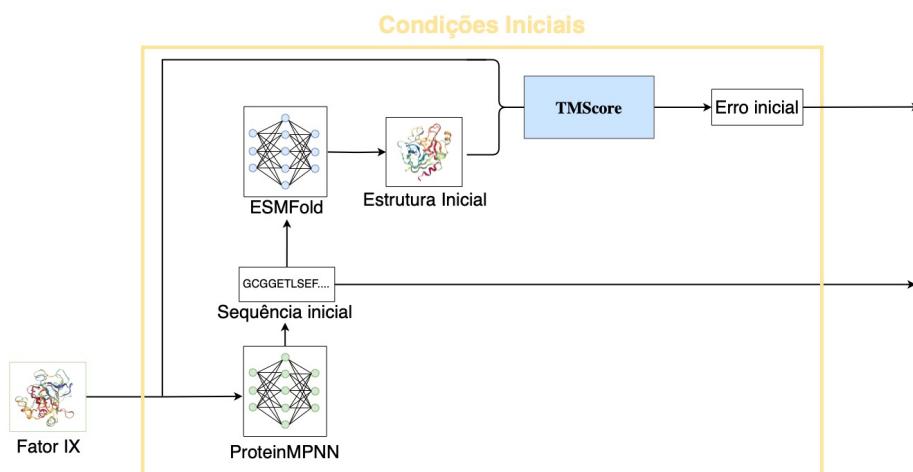


Figura 5.1: Obtenção das condições iniciais

5.2 Treinamento

O módulo de Treinamento foi construído em duas etapas: Estágios I e II, detalhados em 5.2.3 e 5.2.4 respectivamente. Para ambos os estágios, o treinamento se dá através de interações entre dois componentes: O Ambiente de aprendizado e o Agente.

5.2.1 Ambiente de aprendizado

O ambiente de aprendizado é modelado como um MDP e, portanto, é responsável por definir o espaço de ações, o espaço de estados, a função de transição entre estados dado uma ação e a função de recompensa.

Espaço de ações

Definimos uma ação como um vetor bi-dimensional composto pelo índice p de uma posição na sequência e um aminoácido r . A ação será utilizada para realizar uma mutação na proteína, inserindo o r na posição p . De modo a incentivar o Agente a explorar diferentes ações, definimos, para cada iteração, um conjunto de posições e aminoácidos válidos: P_{val} e R_{val} respectivamente. P_{val} é composto por todas as possíveis posições na sequência, com exceção das posições previamente selecionadas dentro do mesmo episódio. Definimos R_{val} sendo igual aos 20 possíveis aminoácidos, com exceção dos aminoácidos que foram selecionados mais do que N_{rep} vezes. Introduzimos N_{rep} como um hiperparâmetro que define a quantidade máxima permitida que um mesmo resíduo pode ser selecionado dentro de um episódio. Desta forma, o espaço de ações, para cada iteração i , é definido por:

$$A_i = \{(p, r) | p \in P_{val_i}, r \in R_{val_i}\} \quad (5.2)$$

Espaço de estados

Definimos o espaço de estados como o conjunto de todas as possíveis sequências de n aminoácidos, onde n é o tamanho da sequência inicial:

$$S = \{(r_1, r_2, r_3, \dots, r_n) | r_i \in R_{encoded} \forall i \in [1, n]\} \quad (5.3)$$

Onde $R_{encoded}$ é o conjunto dos 20 possíveis aminoácidos, cada um representado por um vetor codificado pelo *Encoder*. O *Encoder* consiste em um dicionário que mapeia cada aminoácido para uma representação vetorial que conserva as distâncias entre cada par de aminoácidos estabelecidas por RIOS RICARDO, 2021. Este mapeamento foi construído através de um MDS¹ utilizando 21 dimensões.

¹ Implementação do MDS construída pelo pacote scikit learn, disponível em: <https://scikit-learn.org/stable/modules/generated/sklearn.manifold.MDS.html>

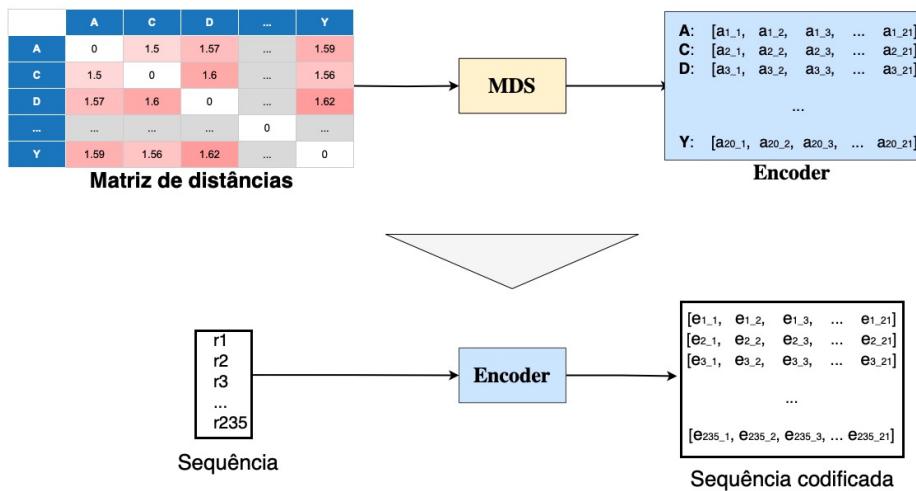


Figura 5.2: Construção e uso do Encoder.

Para escolher a quantidade de dimensões a se utilizar no MDS, definimos o ponto a partir do qual a curva² entre Stress e dimensionalidade tende a se aproximar assintóticamente do eixo x do plano cartesiano. Este ponto, conforme a figura 5.3, é o que possui 21 dimensões.

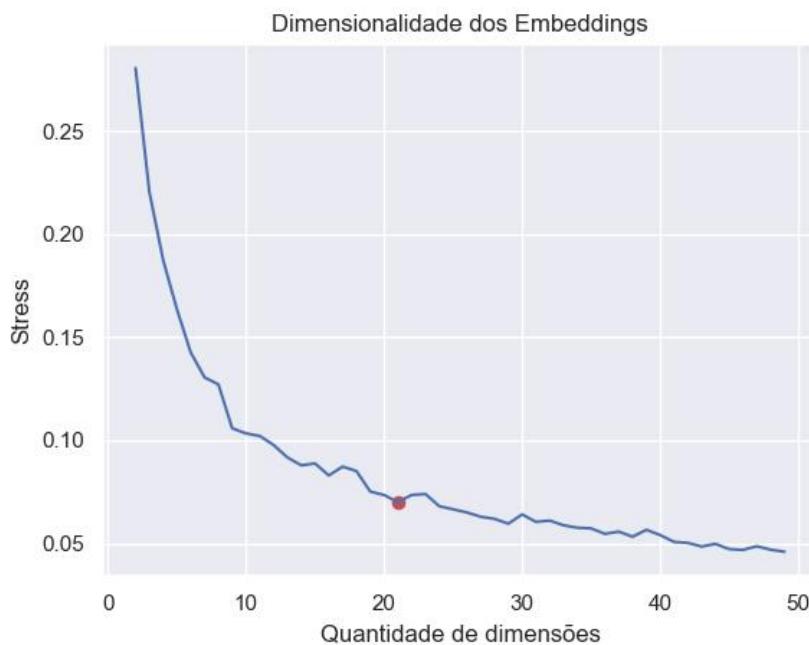


Figura 5.3: Escolha da dimensionalidade dos Embeddings

² Disponível na seção "Encoding Aminoácidos" em <https://github.com/ArthurPimenta0306/Hallucination/blob/main/hpd/notebooks/GeneralAnalysis.ipynb>

Função de transição de estados

A função de transição de estados é caracterizada pela geração de uma nova sequência, resultante da mutação definida pelo Agente. Em outras palavras, é uma função que tem como entrada uma ação e o estado atual e como saída o estado resultante da transição.

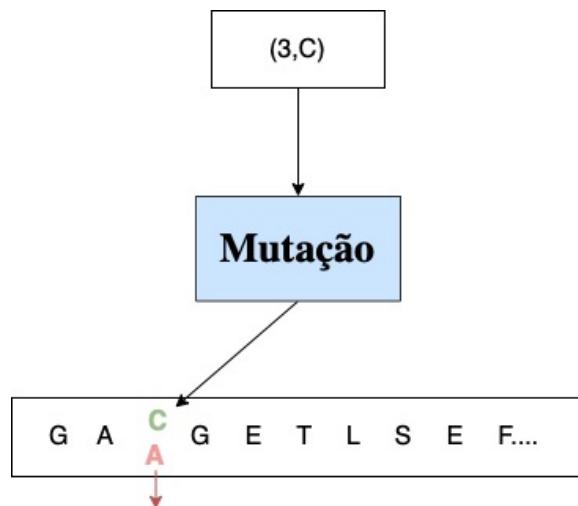


Figura 5.4: Exemplo de mutação. O aminoácido A na posição 3 está sendo substituído pelo o aminoácido C

Função de recompensa

Já a função de recompensa calcula a qualidade da ação selecionada pelo Agente. Nas seções 5.2.3 e 5.2.4 especificamos a função de recompensa de cada estágio de treinamento.

5.2.2 Agente

O Agente é modelado por uma rede neural, batizada de *GenSeq*, cujos parâmetros são otimizados através da técnica *Proximal Policy Optimization* (PPO)³, sendo responsável por decidir qual a melhor mutação a se fazer, dada a sequência de entrada. Em outras palavras, o Agente deve escolher, dentro do espaço de ações, a ação que maximiza a recompensa acumulada. Os hiperparâmetros utilizados no Agente são apresentados na tabela a seguir.

³ Implementação do PPO construída pelo pacote stable baselines, disponível em: https://github.com/Stable-Baselines-Team/stable-baselines3-contrib/tree/master/sb3_contrib/ppo_mask

Hiperparâmetro	Valor
Número de camadas escondidas	2
Número de neurônios por camada escondida	64
Função de ativação	tangente hiperbólica
Otimizador	Adam
Taxa de aprendizagem	3e-4
Número de épocas	10
Fator de desconto (γ)	0.99

Tabela 5.1: Hiperparâmetros do PPO

Após ser processada pelo *Encoder*, a sequência passa pela camada de entrada do *GenSeq* e segue para duas camadas escondidas de 64 dimensões cada. A camada de saída, por sua vez, possui 255 unidades, organizadas em duas partes:

- As primeiras 235 unidades da camadas estão associadas ao primeiro atributo da ação: A posição p da sequência de entrada que deve sofrer mutação. A posição predita pelo Agente corresponde ao índice da unidade de saída com maior valor entre as 235 primeiras.
- Já as 20 últimas unidades de saída estão associadas ao segundo atributo da ação: O índice do aminoácido r que o Agente sugere inserir na posição p . Este valor corresponde ao índice da unidade de saída com maior valor entre as 20 últimas unidades, subtraído de 235.

Por exemplo, suponha que, entre as 235 primeiras unidades, a de maior valor é a terceira, e que, entre as 20 últimas, o maior valor esteja na unidade 240. Nesse caso, a ação sugerida pelo Agente é fazer uma mutação na posição 3, inserindo o aminoácido de índice 5.

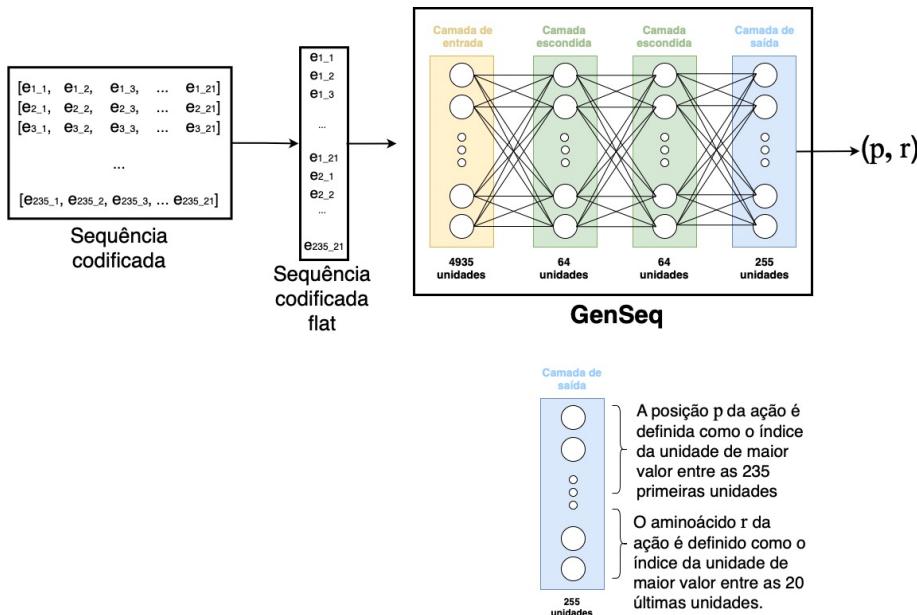


Figura 5.5: Arquitetura da rede neural do Agente (GenSeq)

5.2.3 Treinamento - Estágio I

Tendo em vista o vasto número de ações possíveis, desenvolvemos o Estágio I de treinamento com o objetivo de estimular o Agente a encontrar um subespaço menor de ações para atuar. Neste estágio, construímos o ambiente de aprendizado *EnvI*, onde atribuímos recompensas negativas (ou penalizações) para ações em posições da sequência cujo o *Conservation Score* 3.1.7 é alto, bem como penalizamos ações onde o aminoácido substituído é muito diferente do que fora inserido. Neste sentido, definimos a seguinte função de recompensa:

$$R_I = -(CS(p) + AminoDist(r, r_{prev})) \quad (5.4)$$

Onde p e r são a posição e o aminoácido selecionados pelo Agente, respectivamente. O r_{prev} é o aminoácido que estava na posição p antes da mutação. $CS(p)$ é o *Conservation Score* normalizado da posição p e $AminoDist(r, r_{prev})$ é a medida de similariedade 3.1.8 entre os aminoácidos r e r_{prev} .

O ambiente *EnvI* foi construído seguindo a padronização proposta pelo pacote *gym*⁴ que garante compatibilidade com algoritmos de aprendizado por reforço. Como entrada, o ambiente recebe uma sequência inicial S_{ini} , o *Encoder*, a matriz de similaridade entre aminoácidos *AminoDist*, a função de score de conservação *CS*, e os hiperparâmetros M_{max} e N_{rep} , que determinam, respectivamente, o número máximo de mutações permitidas por episódio e o número máximo de repetições para um mesmo aminoácido dentro do episódio.

Durante a inicialização, o estado atual S recebe a sequência inicial S_{ini} . Além disso, é estabelecido o conjunto de posições válidas P_{val} , que inicialmente contém todas as posições da sequência, e o conjunto de aminoácidos válidos R_{val} , que se inicia com todos os 20 aminoácidos possíveis. Também é inicializado um contador $step_id$, que rastreia o número de iterações realizadas.

A padronização do *gym* prevê a implementação de dois principais métodos: *Reset* e *Step*. O método *Reset* é responsável por restaurar o ambiente ao seu estado inicial, garantindo que cada novo episódio de aprendizado comece a partir de uma condição padronizada.

A interação com o ambiente ocorre por meio do método *Step*, que recebe como entrada uma ação (p, r) , onde p representa a posição da mutação na sequência e r corresponde ao aminoácido que será inserido nessa posição. O primeiro passo da função consiste em armazenar o aminoácido atual de S na posição p , denotado como r_{prev} . Em seguida, a sequência S é modificada com a inserção de r na posição p e convertida em uma representação vetorial por meio da função *Encoder(S)*. A recompensa R_I é calculada e os conjuntos P_{val} e R_{val} são ajustados. Caso a posição p já tenha sido utilizada, ela é removida de P_{val} . De maneira similar, se o aminoácido r já foi escolhido N_{rep} vezes, ele é removido de R_{val} . Isto é feito de modo a evitar com que o modelo vicie em fazer um número limitado de mutações e não explore devidamente o espaço. Para determinar se o episódio deve ser encerrado, a função verifica se o número total de mutações atingiu M_{max} . Se esse limite for alcançado, a

⁴ GYM, API padrão para ambientes de aprendizado por reforço, disponível em: <https://www.gymlibrary.dev/>

variável de controle $done$ é definida como verdadeira, sinalizando o fim do episódio. Por fim, a função retorna a sequência codificada S_{enc} , a recompensa R_I e a variável de controle $done$.

Algorithm 1 Ambiente de aprendizado - Estágio 1

Require: Classe $gym.ENV$,

- 1: sequência inicial S_{ini} ,
- 2: encoder $Encoder$,
- 3: matriz de similaridade entre aminoácidos $AminoDist$,
- 4: função de score de conservação CS ,
- 5: número máximo de mutações por episódio M_{max} ,
- 6: número máximo de repetições do mesmo aminoácido por episódio N_{rep}

Ensure: Classe $EnvI$

- 7: **class** $EnvI$ **herda** $gym.ENV$
 - 8: $S \leftarrow S_{ini}$
 - 9: $P_{val} \leftarrow$ Todas as posições na sequência
 - 10: $R_{val} \leftarrow$ Todos os aminoácidos
 - 11: $step_{id} \leftarrow 0$
 - 12: **function** **RESET()**
 - 13: $S \leftarrow S_{ini}$
 - 14: $P_{val} \leftarrow$ Todas as posições na sequência
 - 15: $R_{val} \leftarrow$ Todos os aminoácidos
 - 16: $step_{id} \leftarrow 0$
 - 17: **end function**
 - 18: **function** **STEP**((p, r))
 - 19: $r_{prev} \leftarrow$ aminoácido na posição p da sequência S
 - 20: $S \leftarrow$ inserir r na posição p de S
 - 21: $S_{enc} \leftarrow Encoder(S)$
 - 22: $R_I \leftarrow -(CS(p) + AminoDist(r, r_{prev}))$
 - 23: **if** $p \in P_{val}$ **then**
 - 24: Remover p de P_{val}
 - 25: **end if**
 - 26: **if** r já foi escolhido N_{rep} vezes **then**
 - 27: Remover r de R_{val}
 - 28: **end if**
 - 29: $done \leftarrow False$
 - 30: **if** $step_{id} \geq M_{max}$ **then**
 - 31: $done \leftarrow True$
 - 32: **end if**
 - 33: $step_{id} \leftarrow step_{id} + 1$
 - 34: **return** $S_{enc}, R_I, done$
 - 35: **end function**
-

O loop de pré treino é construído baseado na interação entre o agente $GenSeq$ e o ambiente $EnvI$. Esse primeiro estágio começa inicializando o ambiente $EnvI$ com a sequência inicial S_{ini} , o $GenSeq$ com pesos aleatórios e o histórico de recompensas R_{hist}

como uma lista vazia. Obtemos S_{enc} codificando S_{ini} através do *Encoder*. S_{enc} consiste na sequência S_{ini} em um formato compatível com *GenSeq*. O *loop* é então inicializado com o *GenSeq* obtendo uma ação (p, r) baseado em S_{enc} . Com a ação (p, r) é realizado um *step* no ambiente, resultando em uma nova sequência S_{enc} , a recompensa R_I associada a essa mutação e a variável *done* que indica se o episódio atingiu o número máximo de mutações. R_I é adicionado ao R_{hist} e o ambiente *EnvI* é reiniciado caso *done* seja verdadeiro. Por fim, os pesos do *GenSeq* são atualizados com base em R_{hist} através do PPO, caso o *batch* tenha sido finalizado. O *loop* se repete até que seja atingido N_{iter} iterações.

Algorithm 2 Treinamento - Estágio I

Require: Número total de iterações N_{iter} ,

- 1: número máximo de mutações por episódio M_{max} ,
- 2: sequência inicial S_{ini} ,
- 3: encoder *Encoder*,
- 4: matriz de similaridade entre aminoácidos *AminoDist*,
- 5: função de score de conservação *CS*,
- 6: número máximo de repetições do mesmo aminoácido por episódio N_{rep} ,
- 7: tamanho do batch *batch_size*

Ensure: Agente pré-treinado *GenSeq*

- 8: $env \leftarrow EnvI(S_{ini}, Encoder, AminoDist, CS, M_{max}, N_{rep})$
 - 9: *GenSeq* \leftarrow Iniciar com pesos aleatórios
 - 10: $S_{enc} \leftarrow Encoder(S_{ini})$
 - 11: $R_{hist} \leftarrow []$
 - 12: **for** $i = 1$ to N_{iter} **do**
 - 13: $(p, r) \leftarrow GenSeq(S_{enc})$
 - 14: $(S_{enc}, R_I, done) \leftarrow env.step(p, r)$
 - 15: Adiciona R_I ao R_{hist}
 - 16: **if** *done* = True **then**
 - 17: $env.reset()$
 - 18: **end if**
 - 19: **if** $i \bmod batch_size = 0$ **then**
 - 20: Atualizar pesos do *GenSeq* baseado em R_{hist} utilizando PPO
 - 21: $R_{hist} \leftarrow []$
 - 22: **end if**
 - 23: **end for**
 - 24: **return** *GenSeq*
-

A implementação do *EnvI*⁵ bem como do primeiro estágio de treinamento⁶ estão disponíveis. A figura a seguir ilustra uma visão geral da relação entre o ambiente de aprendizagem e o agente durante o primeiro estágio de treinamento.

⁵ Disponível em: <https://github.com/ArthurPimenta0306/Hallucination/blob/main/hpd/src/hpd/pipelines/RLenvs/nodes.py>

⁶ Disponível em: <https://github.com/ArthurPimenta0306/Hallucination/blob/main/hpd/src/hpd/pipelines/Modeling/nodes.py>

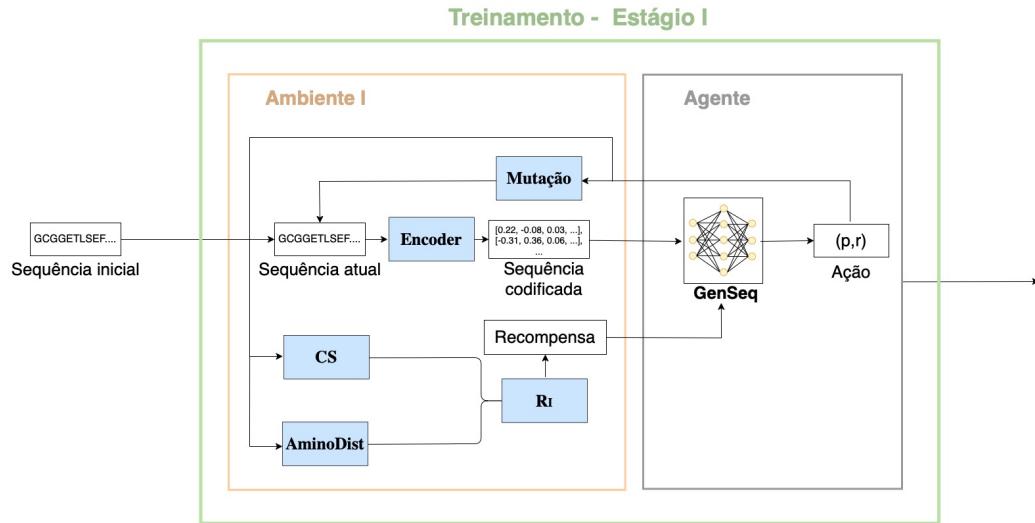


Figura 5.6: Primeiro estágio de treinamento

Neste estágio, o Agente foi treinado com um total de 2 milhões de iterações, podendo executar até 100 mutações por episódio.

Parâmetro	Valor
Número máximo de mutações por episódio	100
Número de iterações	2.000.000
Tamanho do <i>batch</i>	200
N_{rep}	7

Tabela 5.2: Parâmetros preliminares

Após finalizado o primeiro estágio, comparamos o desempenho do *GenSeq* com o desempenho de uma política que define ações aleatoriamente, onde observamos que a mediana da distribuição de recompensas do *GenSeq* é consideravelmente superior ao do Agente aleatório.

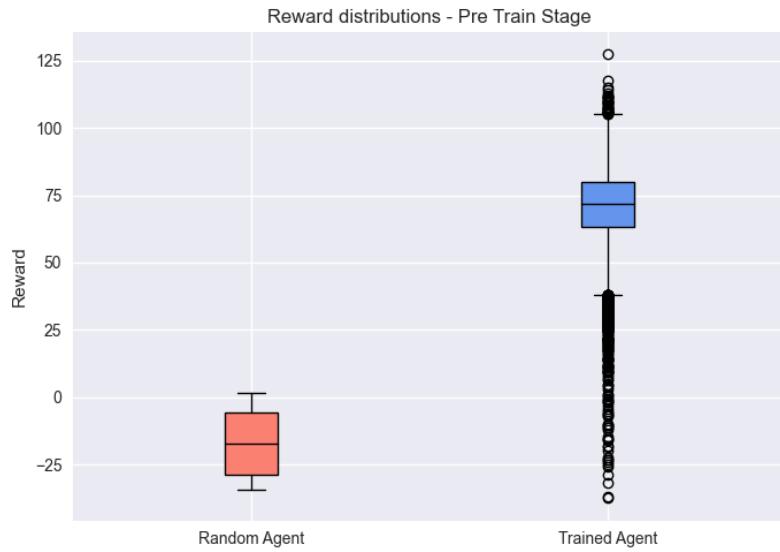


Figura 5.7: Comparação do Agente pré treinado com um Agente aleatório

Observa-se que o *GenSeq* atingiu um platô de recompensas neste ambiente com cerca de 2500 episódios, como ilustrado em 5.8.

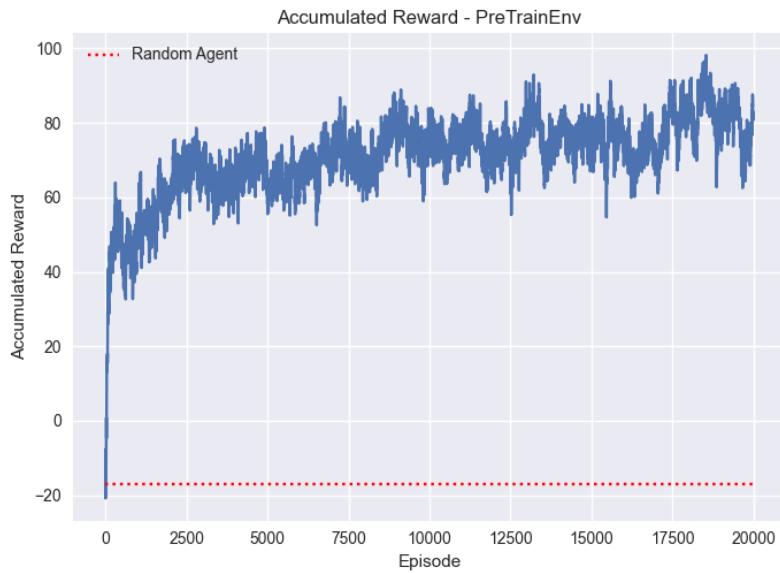


Figura 5.8: Média móvel das recompensas por episódio - treino

5.2.4 Treinamento - Estágio II

O objetivo do segundo estágio de treinamento é fazer com que o agente pré treinado aprenda a escolher ações que maximizem o *TMScore* entre a estrutura gerada e a alvo, i.e,

minimizem o erro $1 - TMScor$ e. Para isto, definimos a função de recompensa como a soma de 3 termos:

$$R_{II} = -aEr_i + b(Er_0 - Er_i) + c(Er_{i-1} - Er_i) \quad (5.5)$$

Onde Er_i e Er_{i-1} são os erros da iteração i e $i-1$ respectivamente, e a , b e c são constantes. O primeiro termo, $-aEr_i$, é a penalização pelo erro atual. O segundo determina uma penalização se o erro atual for maior que o inicial e uma recompensa caso contrário. Análogamente, o terceiro termo penaliza se o erro atual for maior que o anterior e recompensa se for menor. Como o objetivo principal é encontrar sequências com erro menores que o inicial, atribuímos um peso maior ao segundo termo, i.e., $b > a$ e $b > c$. Além disso, consideramos $c > a$ para valorizar reduções do erro ao longo do episódio. Introduzimos também o conceito de vitória e derrota a cada episódio. Consideramos vitória caso o erro final seja menor que o inicial e derrota caso contrário. De modo a valorizar a vitória e penalizar a derrota, ao final de cada episódio é adicionado uma recompensa adicional dada por $2500(Er_0 - Er_f)$, onde Er_f é o erro final, i.e., da última iteração do episódio. Cada episódio é finalizado ao se atingir um número máximo de iterações, ou um limiar de erro. Foi definido um limite superior para o erro Er_{max} de modo a evitar que o Agente atinja erros muito grandes em um mesmo episódio, e um limite inferior Er_{min} para valorizar episódios em que o Agente foi capaz de encontrar "atalhos", i.e., conseguiu reduzir o erro consideravelmente em poucas iterações.

O pior cenário em termos de recompensa para o agente é o caso em que limiar de erro máximo Er_{max} ocorre antes de atingir o número máximo de iterações. Nesse caso, a recompensa adicional é dada pela seguinte expressão:

$$R_{II} \leftarrow R_{II} + 2500(Er_0 - Er_i) + R_{II}(M_{max} - step_{id}) \quad (5.6)$$

Ou seja, um termo adicional de penalização, $R_{II}(M_{max} - step_{id})$, é incluído na recompensa final. Esse termo representa uma estimativa pessimista da recompensa total caso o agente fosse autorizado a completar todas as M_{max} iterações. A suposição subjacente é que, nas iterações restantes $M_{max} - step_{id}$, o agente manteria o desempenho atual, ou seja, continuaria acumulando a mesma recompensa R_{II} associada a um erro superior ao limite máximo Er_{max} . Isso desestimula fortemente trajetórias em que o erro excede Er_{max} precocemente.

A inicialização do segundo ambiente $EnvII$ é feita da mesma forma que $EnvI$, porém com a inclusão da definição de Er_i e Er_{i-1} que iniciam iguais ao erro inicial Er_0 . O ambiente é dependente de parâmetros como S_{ini} , a estrutura do FIX (E_{FIX}), o erro inicial (Er_0), os limiares de erro Er_{max} e Er_{min} , o Encoder, M_{max} , N_{rep} e os coeficientes da função de recompensa (a , b , c).

O método *step* do $EnvII$, assim como no primeiro ambiente, recebe como entrada uma ação (p, r) que é utilizada para realizar a mutação na sequência S . Posteriormente, a sequência é transformada em uma representação codificada pelo *Encoder*, originando a S_{enc} . É feita então a predição da estrutura tridimensional E_S associada a sequência S utilizando o modelo *ESMFold*. O erro da iteração anterior recebe o erro atual, que por sua

vez, é atualizado com o resultado de $1 - TMScore(E_{FIX}, E_S)$. Tendo Er_i e Er_{i-1} , é calculado a recompensa R_{II} seguindo a equação 5.5. A atualização de P_{val} e R_{val} é realizada com a mesma lógica utilizada em $EnvII$. Já o método *reset* pouco difere do método implementado em $EnvI$. A única alteração consiste na atribuição do erro inicial para Er_i e Er_{i-1} .

Algorithm 3 Ambiente de Aprendizado - Estágio II

Require: Classe $gym.ENV$,

- 1: Condições iniciais S_{ini} e Er_0
- 2: Estrutura do FIX E_{FIX} ,
- 3: Limiares de erro Er_{min} e Er_{max} ,
- 4: encoder $Encoder$,
- 5: número máximo de mutações por episódio M_{max} ,
- 6: número máximo de repetições do mesmo aminoácido por episódio N_{rep} ,
- 7: coeficientes da função de recompensa (a, b, c)

Ensure: Classe $EnvII$

```

8: class EnvII herda gym.ENV
9:    $S \leftarrow S_{ini}$ 
10:   $Er_i, Er_{i-1} \leftarrow Er_0$ 
11:   $P_{val} \leftarrow$  Todas as posições na sequência
12:   $R_{val} \leftarrow$  Todos os aminoácidos
13:   $step_{id} \leftarrow 0$ 
14: function RESET()
15:    $S \leftarrow S_{ini}$ 
16:    $Er_i, Er_{i-1} \leftarrow Er_0$ 
17:    $P_{val} \leftarrow$  Todas as posições na sequência
18:    $R_{val} \leftarrow$  Todos os aminoácidos
19:    $step_{id} \leftarrow 0$ 
20: end function
21: function STEP( $(p, r)$ )
22:    $S \leftarrow$  inserir  $r$  na posição  $p$  de  $S$ 
23:    $S_{enc} \leftarrow encoder(S)$ 
24:    $E_S \leftarrow ESMFold(S)$ 
25:    $Er_{i-1} \leftarrow Er_i$ 
26:    $Er_i \leftarrow 1 - TMScore(E_{FIX}, E_S)$ 
27:    $R_{II} \leftarrow -aEr_i + b(Er_0 - Er_i) + c(Er_{i-1} - Er_i)$ 
28:   if  $p \in P_{val}$  then
29:     Remover  $p$  de  $P_{val}$ 
30:   end if
31:   if  $r$  já foi escolhido  $N_{rep}$  vezes then
32:     Remover  $r$  de  $R_{val}$ 
33:   end if
34:    $step_{id} \leftarrow step_{id} + 1$ 
35:    $done \leftarrow False$ 
36:   if  $step_{id} \geq M_{max}$  ou  $Er_i \leq Er_{min}$  ou  $Er_i \geq Er_{max}$  then
37:      $done \leftarrow True$ 
38:     if  $step_{id} = M_{max}$  then
39:        $R_{II} \leftarrow R_{II} + 2500(Er_0 - Er_i)$ 
40:     end if
41:     if  $Er_i \geq Er_{max}$  then
42:        $R_{II} \leftarrow R_{II} + 2500(Er_0 - Er_i) + R_{II}(M_{max} - step_{id})$ 
43:     end if
44:   end if
45:   return  $S_{enc}, R_{II}, done$ 
46: end function

```

O *loop* de treinamento segue a mesma lógica do primeiro estágio, alterando apenas o ambiente de aprendizado de *EnvI* para *EnvII* e suas respectivas dependências. Além disso, o treinamento se inicia com os pesos do *GenSeq* pré treinados, obtidos através do primeiro estágio.

Algorithm 4 Treinamento - Estágio II

Require: Número total de iterações N_{iter} ,

- 1: número máximo de mutações por episódio M_{max} ,
- 2: Condições iniciais S_{ini} e Er_0
- 3: encoder *Encoder*,
- 4: tamanho do batch $batch_size$,
- 5: coeficientes da função de recompensa (a, b, c) ,
- 6: número máximo de repetições do mesmo aminoácido por episódio N_{rep}
- 7: Estrutura do FIX E_{FIX} ,
- 8: Limiares de erro Er_{min} e Er_{max} ,
- 9: Agente pré treinado *GenSeq*

Ensure: Agente treinado *GenSeq*

- 10: $env \leftarrow EnvII(S_{ini}, Er_0, Encoder, (a, b, c), E_{FIX}, Er_{min}, Er_{max}, M_{max}, N_{rep})$
 - 11: $S_{enc} \leftarrow Encoder(S_{ini})$
 - 12: $R_{hist} \leftarrow []$
 - 13: **for** $i = 1$ to N_{iter} **do**
 - 14: $(p, r) \leftarrow GenSeq(S_{enc})$
 - 15: $(S_{enc}, R_{II}, done) \leftarrow env.step(p, r)$
 - 16: Adiciona R_{II} ao R_{hist}
 - 17: **if** $done = True$ **then**
 - 18: $env.reset()$
 - 19: **end if**
 - 20: **if** $i \bmod batch_size = 0$ **then**
 - 21: Atualizar pesos do *GenSeq* baseado em R_{hist} utilizando PPO
 - 22: $R_{hist} \leftarrow []$
 - 23: **end if**
 - 24: **end for**
 - 25: **return** *GenSeq*
-

A implementação do *EnvII*⁷ bem como do segundo estágio de treinamento⁸ estão disponíveis. A figura a seguir ilustra uma visão geral da relação entre o segundo ambiente de aprendizagem e o agente durante o segundo estágio de treinamento.

⁷ Disponível em: <https://github.com/ArthurPimenta0306/Hallucination/blob/main/hpd/src/hpd/pipelines/RLens/nodes.py>

⁸ Disponível em: <https://github.com/ArthurPimenta0306/Hallucination/blob/main/hpd/src/hpd/pipelines/Modeling/nodes.py>

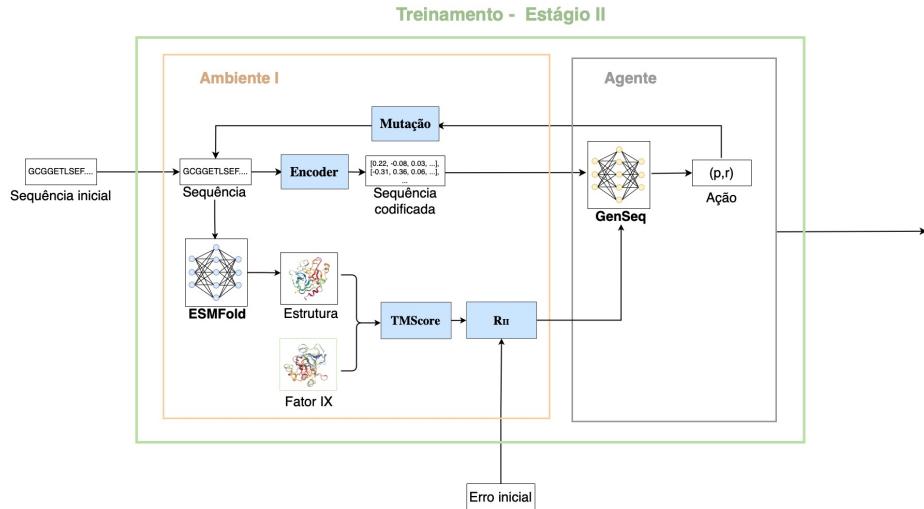


Figura 5.9: Segundo estágio - Treino

Neste estágio, o Agente foi treinado com um total de 60 mil de iterações, podendo executar até 45 mutações por episódio.

Parâmetro	Valor
Número máximo de mutações por episódio	45
Erro mínimo no episódio	0.05
Erro máximo no episódio	0.083
Número de iterações	60.000
a	12
b	200
c	50
N_{rep}	7

Tabela 5.3: Parâmetros preliminares

Assim como no pré treino, a distribuição das recompensas do Agente ao longo do treinamento é bem superior às recompensas de um Agente aleatório.

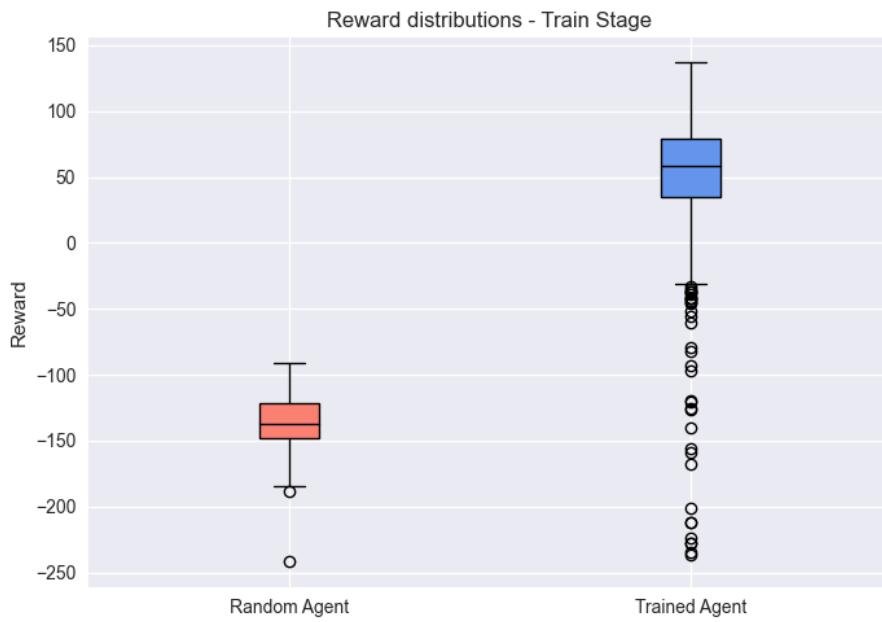


Figura 5.10: Comparação do Agente treinado com um Agente aleatório

Repare que, devido ao pré treino, as recompensas médias do Agente são consideravelmente superiores à recompensa média do Agente aleatório desde os primeiros episódios.

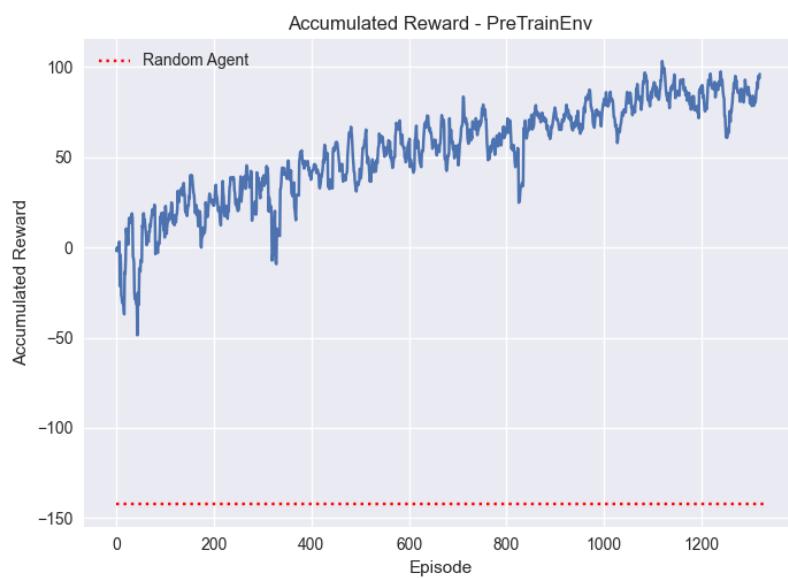


Figura 5.11: Média móvel das recompensas por episódio - treino

5.3 Geração de sequências

Por fim, o módulo de Geração de Sequências utiliza o agente treinado para gerar novas sequências que sejam capazes de mimetizar a estrutura alvo melhor do que a sequência inicial, em termos de *TMScore*. Para isso, o ambiente *EnvII* é inicializado com as mesmas condições utilizadas no segundo estágio de treinamento, incluindo a sequência inicial S_{ini} , o erro inicial Er_0 , o *Encoder*, os coeficientes (a, b, c) e a estrutura alvo E_{FIX} . Para maximizar a diversidade de sequências geradas, as restrições impostas pelos limiares de erro Er_{min} e Er_{max} são removidas, sendo definidos como 0 e 1, respectivamente. Além disso, a geração de sequências é configurada para produzir um total de 235 novas variantes, fixando os parâmetros N_{iter} e M_{max} em 235. O processo de geração consiste em iterativamente obter uma ação com o *GenSeq* e com ela executar o método *step* no *EnvII*.

Algorithm 5 Geração de sequências

Require: Número total de iterações N_{iter} ,

- 1: número máximo de mutações por episódio M_{max} ,
- 2: Condições iniciais S_{ini} e Er_0
- 3: encoder *Encoder*,
- 4: coeficientes da função de recompensa (a, b, c) ,
- 5: número máximo de repetições do mesmo aminoácido por episódio N_{rep}
- 6: Estrutura do FIX E_{FIX} ,
- 7: Limiares de erro Er_{min} e Er_{max} ,
- 8: Agente treinado *GenSeq*

Ensure: Novas sequências *Seqs*

- 9: $env \leftarrow EnvII(S_{ini}, Er_0, Encoder, (a, b, c), E_{FIX}, Er_{min}, Er_{max}, M_{max}, N_{rep})$
- 10: $S_{enc} \leftarrow Encoder(S_{ini})$
- 11: $Seqs \leftarrow []$
- 12: **for** $i = 1$ to N_{iter} **do**
- 13: $(p, r) \leftarrow GenSeq(S_{enc})$
- 14: $(S_{enc}, R_{II}, done) \leftarrow env.step(p, r)$
- 15: Adiciona $env.S$ ao *Seqs*
- 16: **end for**
- 17: **return** *Seqs*

A implementação da geração de sequências está disponível⁹. A figura a seguir representa um esquemático do *loop* de geração de sequências descrito.

⁹ Disponível em: <https://github.com/ArthurPimenta0306/Hallucination/blob/main/hpd/src/hpd/pipelines/Evaluation/nodes.py>

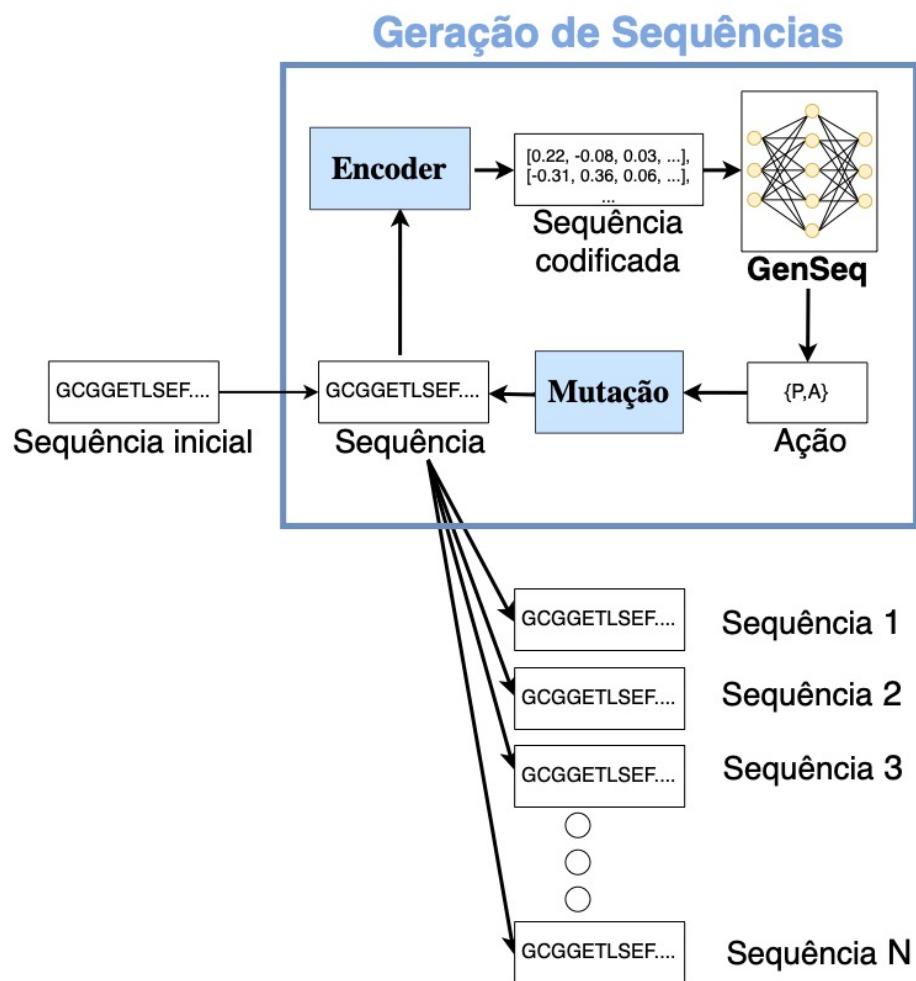


Figura 5.12: Gerando sequência otimizada

Capítulo 6

Resultados

Com o Agente treinado é possível gerar novas sequências seguindo a arquitetura ilustrada na figura 5.12. Foram gerados mais de 200 proteínas diferentes a partir de mutações na sequência inicial. De modo a identificar cada proteína, vamos considerar a ordem com que foi gerada como seu respectivo *ID*. Considerando um limiar de 92% de *TMScore*, selecionamos as 63 primeiras sequências geradas.

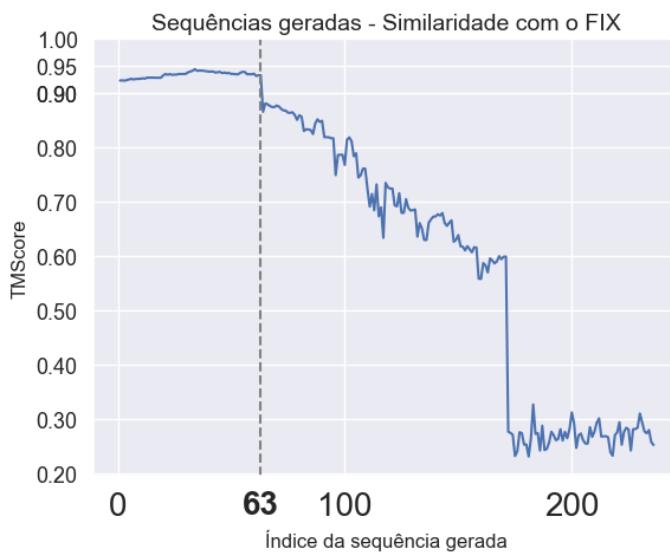


Figura 6.1: Variação da similaridade entre as sequências geradas e o FIX

Os resultados obtidos demonstram que o agente *GenSeq* foi capaz de gerar sequências de aminoácidos que estão associadas a estruturas com elevado grau de similaridade ao FIX nativo. Considerando que o valor de *TMScore* superior a 0.5 já indica similaridade estrutural significativa (JINRUI XU, 2010), os valores obtidos sugerem que as proteínas geradas mantêm a conformação global e o dobramento necessários para sua funcionalidade. A proteína gerada mais similar ao FIX é a de ID 34, tendo *TMScore* igual a 94.48% e RMSD de 1.485 angstroms.

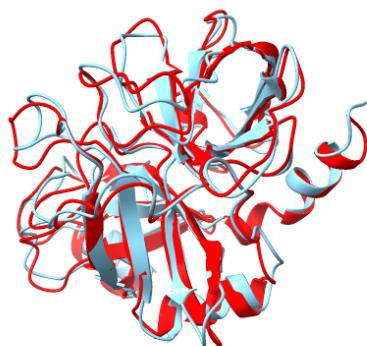


Figura 6.2: Alinhamento entre FIX (em azul) e a proteína ID 34 (em vermelho)

É interessante notar que, apesar da forte semelhança estrutural entre as proteínas, em termos de IS (Idêntidade de Sequência) são sequências muito diferentes, tendo em média apenas 30% de similaridade.

ID	TMscore	RMSD	IS - seq. original
20	93.33%	1.75 Å	30.64%
30	93.62%	1.68 Å	30.21%
34	94.48%	1.48 Å	29.79%
63	93.36%	1.72 Å	26.81%

Tabela 6.1: Generated proteins

6.1 Resposta imunológica

Para mensurar a propensão das proteínas geradas provocarem uma resposta imunológica no organismo, calculamos o *binding affinity* de cada proteína com os epítopenos de quatro grupos diferentes de alelos apresentados na tabela 6.2

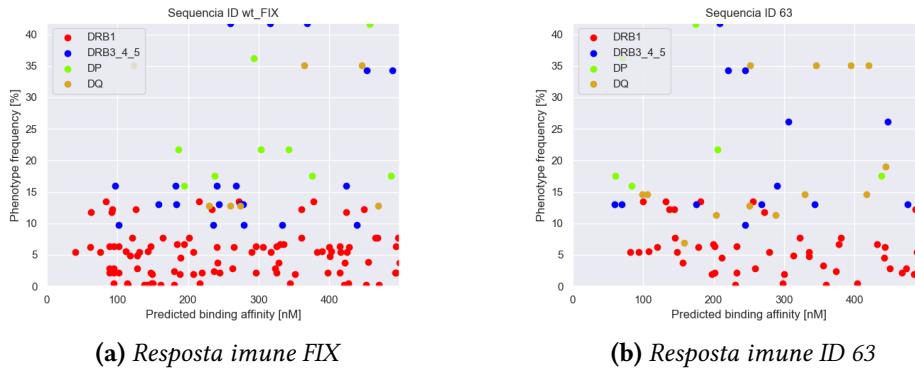
Grupo	Frequência em seres humanos
DP	25%
DQ	20%
DRB1	5%
DRB3_4_5	21%

Tabela 6.2: Grupos de alelos considerados e a frequência com que ocorrem em seres humanos.

Para esta análise, consideramos apenas epítopenos associados a valores de *binding affinity* menores que 500nm, conforme recomendado por MASSIMO ANDREATTAS, 2018. Nas figuras a seguir é possível visualizar a quantidade, *binding affinity* e frequência de ocorrência dos epítopenos por cada grupo de alelo. Ao se comparar o resultado do FIX e da proteína de ID

6.1 | RESPOSTA IMUNOLÓGICA

63, é possível notar uma redução significativa da quantidade de epítópos com ligação forte, influenciado principalmente pelo resultado do grupo DRB1.



A propensão a provocar uma resposta imune não está apenas relacionada à quantidade de epítópos, mas também é diretamente proporcional a frequência de ocorrência dos alelos e inversamente proporcional ao *binding affinity*. Neste sentido, para mensurar qual proteína induz a uma melhor resposta imune, propomos a métrica *IMI* (Imuno Índice), que consiste na média da razão entre *binding affinity* (Af_i) e frequência (Fr_i), dividido pela quantidade de epítópos (N):

$$IMI = \frac{1}{N} \sum_{i=1}^N \frac{1}{N} \frac{Af_i}{Fr_i} \quad (6.1)$$

Desta forma, quanto maior o IMI, menor risco de induzir a uma resposta imune. De modo geral, as 4 últimas sequências geradas possuem um IMI superior ao do FIX: IDs 60, 61, 62 e 63.

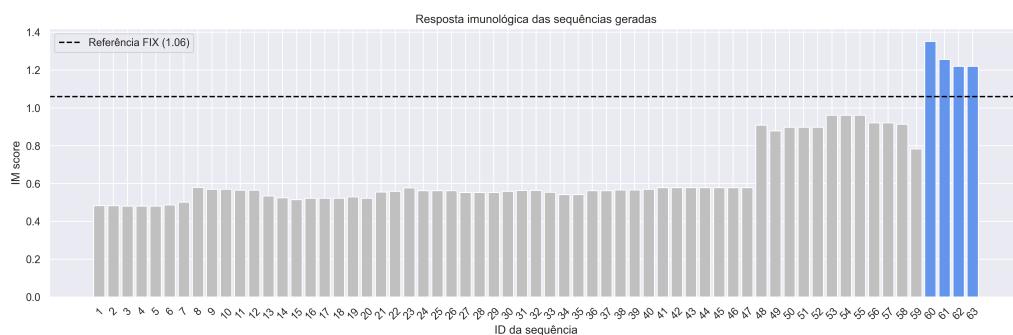


Figura 6.4: Comparação do IMI entre as proteínas geradas e o FIX

Calculando o IMI para cada grupo de alelo separadamente, observa-se que grande parte das sequências geradas possuem uma resposta imune mais favorável que o FIX para os grupos DRB3, DRB4 e DRB5. Para o grupo DRB1, as sequências a partir do ID 48 em diante obtiveram IMI superior ao FIX. Já para os grupos DQ e DP, nenhuma sequência superou o IMI do FIX.

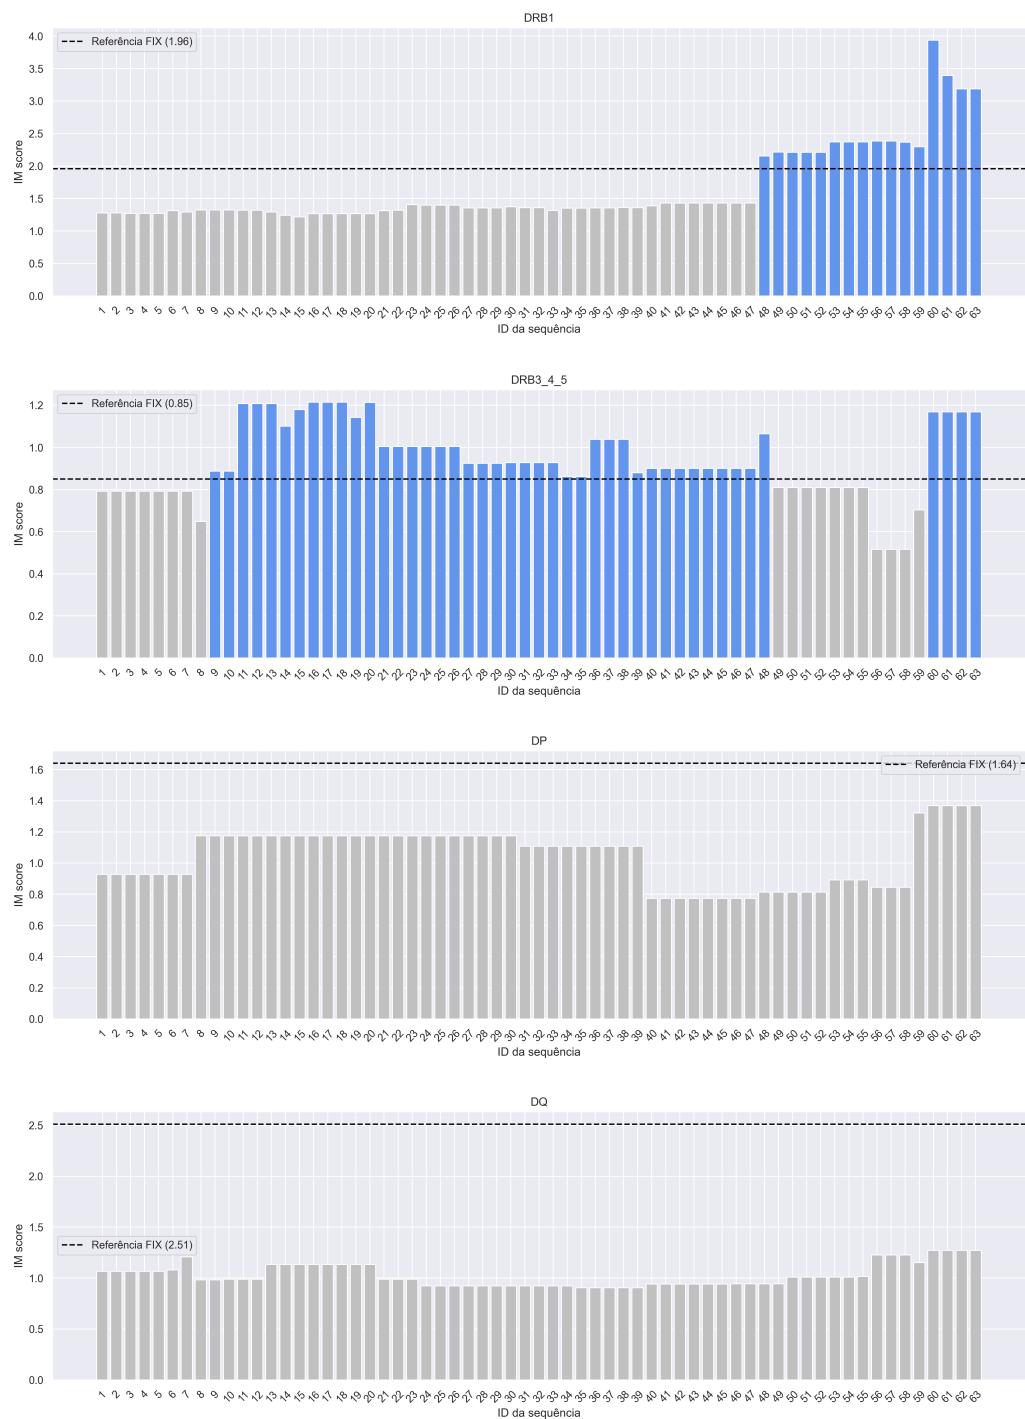


Figura 6.5: IMI calculado para cada grupo de alelo

6.2 Docking

Ao projetar proteínas capazes de substituir o FIX no tratamento da Hemofilia B, um aspecto crítico é garantir que as proteínas geradas possuem uma interação eficaz ou até mais favorável com o FVIII se comparado ao FIX. Para isto, realizamos análises de docking molecular de cada sequência gerada com o FVIII, calculando métricas que capturam

diferentes características da interface proteína-proteína. Ilustramos a seguir os resultados obtidos para as métricas *CMS*, *IBSASA*, *SAP Score* e *DDG*. Estão destacadas em azul as proteínas que superaram o FIX em cada métrica. Em termos de *CMS*, que quantifica a área da superfície de contato, obtivemos 56 proteínas (89% do total) superiores ao FIX, sugerindo interfaces de ligação maiores para essas sequências. O *DDG*, que mede a estabilidade da interação, indicou que 46 proteínas (73% do total) são mais estáveis (*DDG* menor) do que o FIX. O *IBSASA*, que mede a área de superfície enterrada na interface, indicou que 51 proteínas (81% do total) foram superiores ao FIX. Por fim, em termos de *SAP Score*, praticamente todas as proteínas geradas obtiveram valores muito próximos ao calculado para o FIX, tendo 51 proteínas levemente mais favoráveis (81% do total), i.e., formando complexos menos propensos à agregação. Em geral, 30 proteínas (48% do total) superaram o FIX em todas as métricas, sugerindo que as proteínas geradas podem formar complexos eficientes com o FVIII.

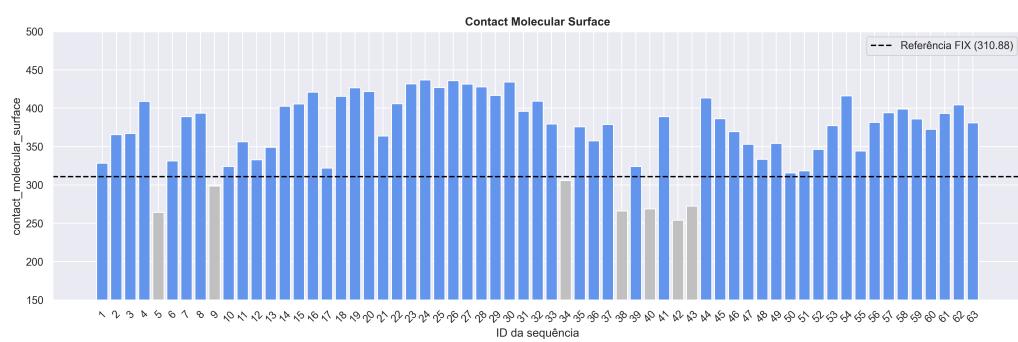


Figura 6.6: Resultado do CMS entre as proteínas geradas e o fator VIII

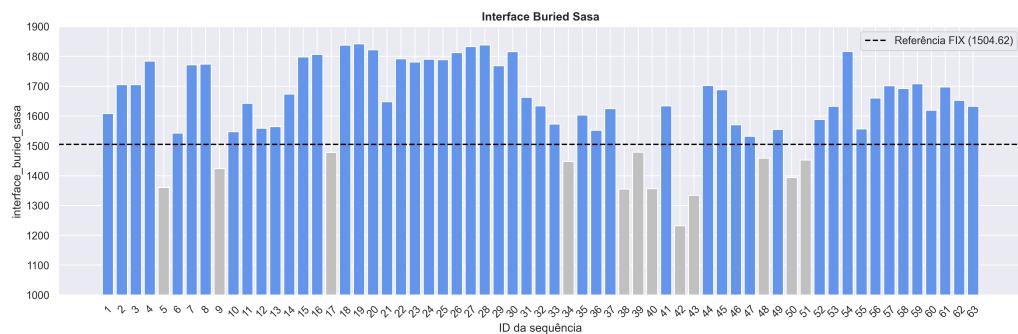


Figura 6.7: Resultado do IBSASA entre as proteínas geradas e o fator VIII

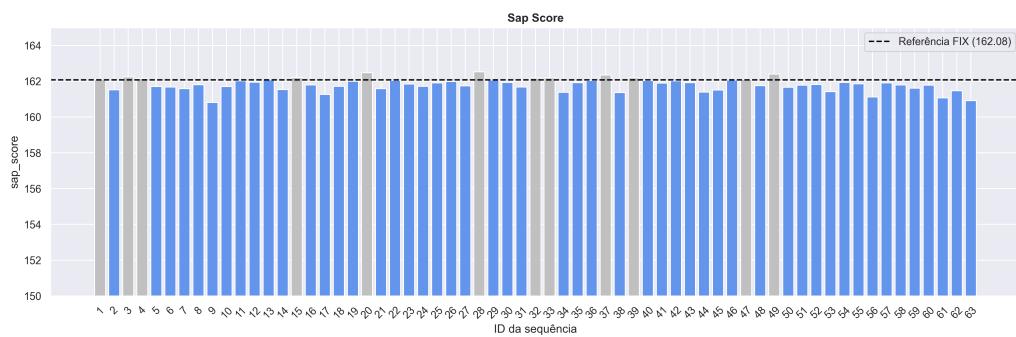


Figura 6.8: Resultado do SAP Score entre as proteínas geradas e o fator VIII

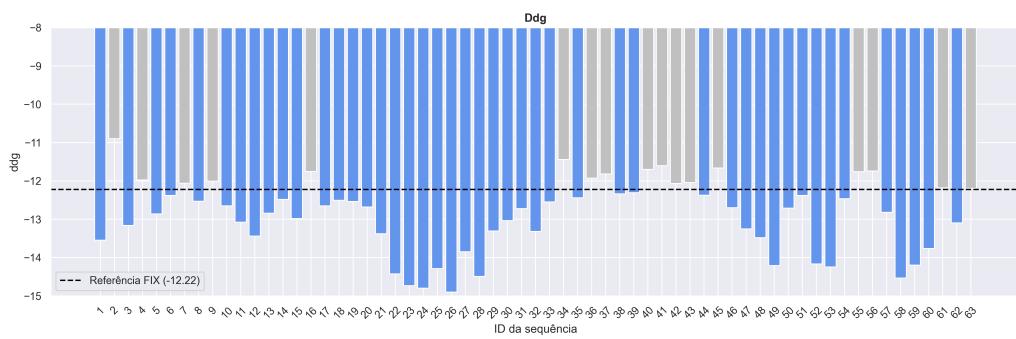


Figura 6.9: Resultado do DDG entre as proteínas geradas e o fator VIII

Capítulo 7

Conclusão

Este trabalho apresentou um novo paradigma para o desenvolvimento de proteínas terapêuticas, aplicando aprendizado por reforço profundo para otimizar a sequência do fator IX (FIX), com o objetivo de melhorar sua estabilidade estrutural, reduzir a imunogenicidade e potencializar sua eficácia no tratamento da hemofilia tipo B.

A abordagem proposta combinou metodologias avançadas de modelagem molecular e inteligência artificial para explorar de maneira eficiente o vasto espaço de sequências proteicas. Utilizando o algoritmo *Proximal Policy Optimization* (PPO) desenvolvemos o *GenSeq*, um modelo capaz de realizar mutações guiadas em sequências proteicas, permitindo a evolução de variantes do FIX por meio de um processo iterativo guiado por métricas estruturais. A validação das proteínas geradas foi realizada por meio de análises computacionais, incluindo cálculos de similaridade estrutural com o *TMScore*, avaliação da interação proteína-proteína através do *docking* molecular com o Fator VIII e identificação da presença de epítópos imunogênicos nas sequências geradas. Os resultados indicaram que algumas variantes apresentam potencial terapêutico promissor. Em relação aos objetivos estabelecidos, todos foram atendidos:

- 1. Obter um conjunto de sequências de aminoácidos que mimetizem a estrutura do FIX baseado na métrica TMScore:** Foram geradas diversas variantes com alta similaridade estrutural ao FIX nativo, sendo 63 delas com *TMScore* superior a 92%, validando a capacidade do *pipeline* em preservar a conformação tridimensional desejada.
- 2. Avaliar, dentro do conjunto de proteínas obtidas em 1, quais possuem potencial de substituir o FIX de modo tornar o tratamento de Hemofilia tipo B mais acessível e eficiente:** As análises computacionais indicaram que várias das proteínas geradas apresentaram maior estabilidade de interação com o Fator VIII (FVIII) e menor risco imunogênico segundo a nova métrica introduzida, o Índice de Compatibilidade Imunológica (IMI).
- 3. Desenvolver um pipeline genérico que produza sequências que mimetizem uma estrutura qualquer:** O *pipeline* possui arquitetura modular, permitindo a parametrização da estrutura alvo, da função de recompensa e dos critérios de avaliação. Dessa forma, ele pode ser aplicado a outros casos de interesse em bioengenharia e

no desenvolvimento de proteínas terapêuticas personalizadas.

Além disso, neste trabalho foi introduzido o IMI (Imuno Índice), uma métrica desenvolvida para quantificar a compatibilidade imunológica de proteínas projetadas em relação ao perfil imune da população humana. O IMI mede o desalinhamento entre os epítopos preditos em uma proteína e a frequência dos alelos na população, permitindo avaliar a propensão de uma resposta imunológica adversa. Esta métrica foi fundamental para comparar as variantes geradas e identificar quais proteínas apresentavam menor risco de desencadear uma resposta imunológica.

A resposta à pergunta científica que este trabalho se propôs a responder é positiva. É possível, por meio de *Sequence Design* com aprendizado por reforço profundo, projetar variantes do FIX com propriedades otimizadas para uso terapêutico. Ainda que os resultados sejam preliminares e necessitem de validação experimental em laboratório (wet lab), os dados computacionais apontam para um caminho viável na geração de proteínas terapêuticas personalizadas e com menor risco imunológico.

Apêndice A

Comandos e Parametrizações

Neste apêndice apresentamos os comandos e suas parametrizações utilizados para a execução dos softwares que constituem o *pipeline* e os métodos de avaliação.

Comando para execução - *ProteinMPNN*

```

1  python src/ProteinMPNN/protein_mpnn_run.py \
2    --pdb_path {structure_path} \
3    --pdb_path_chains {chains_to_design} \
4    --out_folder tmp \
5    --num_seq_per_target 1 \
6    --sampling_temp "0.5" \
7    --seed 37 \
8    --batch_size 1

```

Parametrização - *ProteinMPNN*

1. **pdb_path**: data/05_model_input/fixa_human_SP_renumber.pdb. Caminho até o arquivo da estrutura do FIX.
2. **pdb_path_chains**: "H". Cadeia proteica a ser predita.
3. **out_folder**: "tmp". Nome do diretório temporário.
4. **num_seq_per_target**: 1. Quantidade de sequências geradas.
5. **sampling_temp**: 0.5. Temperatura de amostragem. Quanto menor, mais conservadora a predição.
6. **seed**: 37. Semente aleatória para reproduzibilidade da predição.
7. **batch_size**: 1. Tamanho do batch utilizado para inferência.

Comando para execução - *ESMFold*

```

1  curl -X POST --data "{initial_seq}" https://api.esmatlas.com/foldSequence/v1/
   pdb/ > tmp/pred_initial_structure.pdb

```

Parametrização - *ESMFold*

1. **data:** String contendo a sequência de aminoácidos. Ex: "AACYA...".

Comando para execução - *TMScore*

```
1   ./USalign -outfmt 2 {path_structure_1} {path_structure_2}
```

Parametrização - *TMScore*

1. **path_structure_1:** Caminho até o arquivo .pdb da estrutura protéica referência.
2. **path_structure_2:** Caminho até o arquivo .pdb da segunda estrutura protéica a ser comparada.

Comando para execução - *Rosetta Docking*

```
1   ../rosetta.source.release-371/main/source/bin/docking_protocol.default.
     macosclangrelease -ignore_unrecognized_res @flag_file -out:prefix
     process_1_
```

Parametrização - *Rosetta Docking*

1. **ignore_unrecognized_res:** Atributo utilizado para ignorar resíduos não reconhecidos pelo *Rosetta*.
2. **flag_file:** Arquivo .flag contendo os parâmetros de execução do *Rosetta Docking*.
3. **out:prefix:** Prefixo para os arquivos de saída gerados pelo *Rosetta Docking*.

Parametrização - Arquivo .flag utilizado como *input* do *Rosetta Docking*

1. **in:file:s:** Especifica o caminho para o arquivo PDB do complexo de entrada (FVIII junto de uma proteína gerada), que será utilizada no processo de docking. Ex: complex_step_1.pdb
2. **nstruct: 1000.** Define o número de modelos (poses de encaixe entre as duas proteínas) a serem gerados no processo de *docking*.
3. **partners: A_H.** Especifica quais cadeias da estrutura PDB interagem no *docking*.
4. **dock_pert: 3 8.** Aplica uma perturbação inicial na orientação da proteína antes do docking. O primeiro valor (3) representa um deslocamento translacional em Ångströms, enquanto o segundo (8) define uma rotação em graus.
5. **out:path:all:** Define o diretório onde todos os arquivos de saída do docking serão armazenados. Ex: output_files/

Comando para execução - *netMHCIIpan*

```
1   cores=2
2   while read p; do
3       ls *.fasta | parallel -j $cores -k \
4           ".../netMHCIIpan-4.1/netMHCIIpan -a $p -f {} \
5           -length 15,16,17,18,19,20 -BA -context > {}-$p-output.txt"
6   done < selected_alleles.txt
```

Parametrização - Análise Imunológica com *NetMHCIIpan*

1. **cores**: 2. Número de núcleos de processamento utilizados para paralelização.
2. **selected_alleles.txt**: Arquivo contendo a lista dos alelos de MHC II humanos que serão utilizados na predição. Foram utilizados 46 alelos de MHC II frequentes na população humana, pertencentes aos grupos DP, DQ, DRB1 DRB3, DRB4 e DRB5.
3. **length**: 15,16,17,18,19,20. Define os comprimentos dos peptídeos que serão extraídos da sequência e avaliados quanto à afinidade de ligação. Esses comprimentos são típicos de epítópos apresentados por MHC II.
4. **BA**: Ativa o modo de predição baseado na afinidade de ligação (Binding Affinity).
5. **context**: Habilita a consideração de regiões adjacentes aos peptídeos, o que aumenta a precisão da predição.

Referências

- [ADI BEN CHORIN 2020] et al. ADI BEN CHORIN. “Consurf-db: an accessible repository for the evolutionary conservation patterns of the majority of pdb proteins”. *Protein Sci* (2020) (citado na pg. 16).
- [J. D. e. AL 2022] J. Dauparas et AL. “Robust deep learning–based protein sequence design using proteinmpnn”. *Science* (2022) (citado nas pgs. 3, 7, 24).
- [Z. L. e. AL 2022] Zeming Lin et AL. “Language models of protein sequences at the scale of evolution enable accurate structure prediction”. *bioRxiv* (2022) (citado nas pgs. 6, 24).
- [E. C. M. e. AL. 2023] Elaine C. Meng; et AL. “Ucsf chimeraX: tools for structure building and analysis”. *Protein Science* (2023) (citado na pg. 25).
- [S. C. G. e. AL. 2013] Samantha C. Gouw et AL. “Factor viii products and inhibitor development in severe hemophilia a”. *New England Journal of Medicine* (2013) (citado na pg. 1).
- [ALESSANDRO SETTE 2020] Bjoern Peters; Morten Nielsen e ALESSANDRO SETTE. “T cell epitope predictions”. *Annual Reviews* (2020) (citado na pg. 14).
- [ANGERMUELLER C 2019] et al ANGERMUELLER C. “Model-based reinforcement learning for biological sequence design”. In: ed. por 8th International Conference on LEARNING REPRESENTATIONS (ICLR 2020). 2019 (citado na pg. 7).
- [B 2019] Kuhlman B. “Designing protein structures and complexes with the molecular modeling program rosetta”. *J Biol Chem* (2019) (citado nas pgs. 2, 5).
- [BISHOP 2006] M. Christopher BISHOP. *Pattern Recognition and Machine Learning*. New York: Springer, 2006 (citado nas pgs. 18–20).
- [CHARIF 2007] J. CHARIF D. Lobry. “R. in structural approaches to sequence evolution”. *Springer* (2007) (citado na pg. 16).
- [COVENTRY 2021] Brian COVENTRY. “Learning How to Make Mini-Proteins that Bind to Specific Target Proteins”. Tese de dout. University of Washington, 2021 (citado na pg. 13).

- [CRAIG M. KESSLER 1995] Alice J. Cohen e CRAIG M. KESSLER. “Treatment of inherited coagulation disorders”. *The American Journal of Medicine* 99.6 (1995), pp. 675–682. ISSN: 0002-9343. DOI: [https://doi.org/10.1016/S0002-9343\(99\)80256-3](https://doi.org/10.1016/S0002-9343(99)80256-3). URL: <https://www.sciencedirect.com/science/article/pii/S0002934399802563> (citado na pg. 5).
- [DIEST E DOUGALD M. MONROE 2024] Mettine H. A. Bos; Rianne E. van DIEST E DOUGALD M. MONROE. “Blood coagulation factor ix: structural insights impacting hemophilia b therapy”. *American Society for Hematology Journal BLOOD* (2024) (citado nas pgs. 3, 11, 12).
- [EDDY 2004] S. R. EDDY. “Where did the blosum62 alignment score matrix come from?” *Nature Biotechnology* (2004) (citado na pg. 16).
- [FIGUEIREDO 2018] Jonathas FIGUEIREDO. “Aplicação de algoritmos de aprendizagem por reforço para controle de navios em águas restritas”. *Universidade de São Paulo* (2018) (citado na pg. 19).
- [HAIPENG GONG 2022] Wenzhe Ding; Kenta Nakai e HAIPENG GONG. “Protein design via deep learning”. *Oxford Academic* (2022) (citado na pg. 1).
- [JEFFREY SKOLNICK 2004] Yang Zhang e JEFFREY SKOLNICK. “Scoring function for automated assessment of protein structure template quality”. *Proteins: Structure, Function, and Bioinformatics* (2004) (citado nas pgs. 3, 14, 15).
- [JINRUI XU 2010] Yang Zhang e JINRUI XU. “How significant is a protein structure similarity with tm-score = 0.5?” *Bioinformatics* (2010) (citado na pg. 47).
- [JOHN N. TSITSIKLIS 2001] Vijay R. Konda e JOHN N. TSITSIKLIS. “Actor-critic algorithms”. *Society for Industrial and Applied Mathematics* 42 (abr. de 2001) (citado na pg. 20).
- [JUMPER 2021] et al. JUMPER J. “Highly accurate protein structure prediction with alpha-fold”. *Nature* (2021) (citado na pg. 6).
- [KRUSKAL 1964] J.B. KRUSKAL. “Nonmetric multidimensional scaling: a numerical method”. *Psychometrika* (1964) (citado na pg. 22).
- [MANNUCCI 2020] Pier Mannuccio MANNUCCI. “Emophilia therapy: the future has begun.” *Haematologica* (2020) (citado na pg. 1).
- [MASSIMO ANDREATTAS 2018] Kamilla K. Jensen e MASSIMO ANDREATTAS. “Improved methods for predicting peptide binding affinity to mhc class ii molecules”. *Immunology* (2018) (citado nas pgs. 26, 48).
- [MASSIMO FRANCHINI 2014] Pier Mannuccio Mannucci e MASSIMO FRANCHINI. “Emerging drugs for hemophilia b”. *Biologics: Targets and Therapy* (2014) (citado na pg. 5).

REFERÊNCIAS

- [OLEG KLIMOV 2017] John Schulman; Filip Wolski; Prafulla Dhariwal; Alec Radford e OLEG KLIMOV. “Proximal policy optimization algorithms”. *ArXiv* (2017) (citado nas pgs. 4, 20, 21, 24).
- [PELLEGRINI 2007] Jerônimo PELLEGRINI. *Processos de Decisão de Markov: um tutorial*. XIV. RITA, 2007 (citado na pg. 17).
- [PETER WALTER 2002] Bruce Alberts; Alexander Johnson; Julian Lewis; Martin Raff; Keith Roberts e PETER WALTER. *Molecular Biology of the Cell*. Garland Science, 2002 (citado nas pgs. 9–11).
- [PIER MANNUCCIO MANNUCCI 2005] Elena Santagostino; Maria Elisa Mancuso; Angiola Rocino; Giacomo Mancuso; Maria Gabriella Mazzucconi; Annarita Tagliaferri; Maria Messina e PIER MANNUCCIO MANNUCCI. “Environmental risk factors for inhibitor development in children with hemophilia a: a case–control study”. *Hematologica* (2005) (citado nas pgs. 1, 5).
- [PIMENTA 2025] Arthur M. PIMENTA. *Protein design by deep reinforcement learning*. 2025. URL: <https://github.com/ArthurPimenta0306/Hallucination> (citado na pg. 4).
- [RIOS RICARDO 2021] Lopes Tiago J. S.; Nogueira Tatiane e RIOS RICARDO. “Prediction of hemophilia a severity using a small-input machine-learning framework”. *Nature* (2021) (citado nas pgs. 16, 17, 21, 24, 30).
- [RIOS RICARDO 2022] Lopes Tiago J. S.; Nogueira Tatiane e RIOS RICARDO. “A machine learning framework predicts the clinical severity of hemophilia b caused by point-mutations”. *Frontiers in Bioinformatics* (2022) (citado nas pgs. 16, 23–25).
- [SANTAGOSTINO 2017] Maria Elisa Mancuso; Elena SANTAGOSTINO. “Outcome of clinical trials with new extended half-life fviii/ix concentrates.” *J Clin Med.* (2017) (citado na pg. 5).
- [TIAGO J. LOPES 2024] Arthur M. Pimenta; Roberto Hirata Jr. e TIAGO J. LOPES. *Protein design and deep learning: a new frontier in hemophilia b management*. Madrid, Espanha: World Federation of Hemophilia (WFH), 2024. URL: https://www.postersessiononline.eu/173580348_eu/congresos/WFH2024/aula/-PO_34_WFH2024.pdf (citado na pg. 4).
- [YANG ZHANG 2022] Chengxin Zhang; Morgan Shine; Anna Marie Pyle e YANG ZHANG. “Us-align: universal structure alignments of proteins, nucleic acids, and macromolecular complexes”. *Nat Methods* (2022) (citado nas pgs. 16, 24).